CrediRisk

Evaluación del riesgo crediticio con un ensamble de redes neuronales profundas

Ensamble de 3 redes neuronales

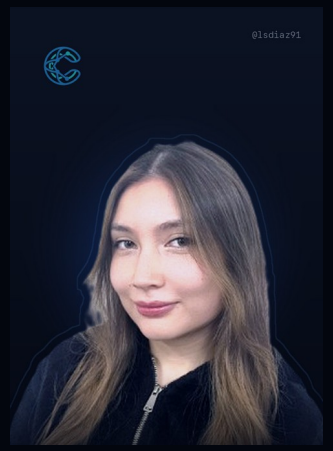
AUC 0,745 en clientes nunca vistos



Leidy Vanessa
Guecha Alape



Sharick Natalia
Hernández Gómez



Laura Sofía
Díaz Suárez



Iván Camilo
Solano Sánchez



Cristian Camilo
Martínez Delgado

Redes Neuronales Profundas · Universidad Católica de Colombia · 2026

Contenido de la presentación

01
Datos
Qué queremos predecir, cómo dividimos los datos y por qué pasamos de 23 a 44 variables.

02
Modelo
Cómo aprende una red, qué funciones de activación usamos y cómo funciona el ensamble de tres redes.

03
Pruebas
Las 164 redes entrenadas: qué se probó en cada etapa y qué se decidió.

04
Aprendizaje
Épocas, curvas de aprendizaje y cinco pruebas para saber si el modelo aprendió o memorizó.

05
Resultados
Cómo se mide el error, resultados en prueba, matriz de confusión y variables importantes.

06
Cierre
Limitaciones del estudio, conclusiones y página web.

El problema que resuelve el modelo

Un banco recibe miles de solicitudes de crédito de consumo y debe decidir a quién prestarle. El modelo estudia los datos de cada solicitante y estima qué tan probable es que pague.

QUÉ HACE EL MODELO

Recibe los datos de una solicitud y responde con una probabilidad entre 0 % y 100 % de que la persona sea apta:

APTO (1)

probablemente pagará

NO APTO (0)

riesgo de no pagar

Regla de decisión: si la probabilidad es 50 % o más, el cliente se clasifica como APTO; si es menor, como NO APTO. A esto se le llama clasificación binaria.

49.650

solicitudes de crédito en la base de datos

23

datos por persona: edad, ingresos, deudas, historial de pagos, tipo de contrato…

50 / 50

mitad aptos y mitad no aptos: adivinar al azar acertaría el 50 %

División de los datos (70 / 15 / 15)

Antes de hacer cualquier cálculo, los 49.650 clientes se dividieron en tres grupos al azar, manteniendo la misma proporción de aptos en cada uno (semilla 42).



Entrenamiento

34.755 clientes · 70 %

Es el «libro de ejercicios». Con estos clientes la red aprende y ajusta sus pesos.

Validación

7.447 clientes · 15 %

Son los «simulacros». Sirven para comparar versiones y decidir cuándo parar. La red nunca aprende de ellos.

Prueba (Test)

7.448 clientes · 15 %

Es el «examen final». Se guardó sin tocar y se usó una sola vez, al final del proyecto.

Por qué tres grupos: si usáramos el examen final para tomar decisiones, la nota final ya no sería honesta. Por eso todas las decisiones se tomaron con validación y la prueba se usó una sola vez.

Preparación de los datos

Una red neuronal solo entiende números, y funciona mejor si todos están en una escala parecida. Por eso los datos pasan por cuatro pasos antes de entrar a la red.

PASO 1

Limpiar

Se quita el número de solicitud (no dice nada de la persona) y la columna INCUMPLIO_PAGO, que es la respuesta disfrazada: dejarla sería hacer trampa.

PASO 2

Rellenar vacíos

Si a alguien le falta un dato, se usa el valor típico (la mediana) y se agrega una columna que avisa «este dato faltaba», porque eso también puede ser información.

PASO 3

Suavizar extremos

Ingresos, deudas y montos tienen unos pocos valores enormes. Se recortan los extremos y se comprimen con logaritmo para que no dominen a los demás.

PASO 4

Traducir y escalar

Las categorías (estado civil, contrato…) se convierten en columnas de 0 y 1, y todas las columnas se llevan a la misma escala (promedio 0, desviación 1).

Sin fuga de información: las medianas, los recortes y la escala se calcularon solo con el grupo de entrenamiento y luego se aplicaron igual a validación, prueba y a clientes nuevos.

De 23 datos a 44 variables de entrada

Cada solicitante llega con 23 datos, pero la red recibe 44 números. La diferencia no es información nueva: es la forma de escribir esos mismos datos para que la red los entienda.

19 numéricas + **7** avisos de dato faltante + **18** columnas de categorías = **44** entradas de la red

19 NUMÉRICAS → 19 COLUMNAS

Edad, ingreso mensual, obligaciones, ingreso disponible, monto, plazo, cuota, tasa de interés, endeudamiento, score crediticio, créditos activos, saldo, cuotas y días de mora, pagos oportunos, antigüedad laboral y como cliente, patrimonio y personas a cargo.

Cada una sigue siendo una sola columna (ya escalada).

7 AVISOS DE DATO FALTANTE

Las variables con más del 1 % de vacíos reciben una columna extra de 0/1 que dice si el dato faltaba:

saldo de créditos · créditos activos · antigüedad laboral · antigüedad como cliente · pagos oportunos · obligaciones · cuotas en mora

Que falte un dato también puede decir algo de la persona.

4 CATEGORÍAS → 18 COLUMNAS

Estado civil	**5 columnas**
Tipo de contrato	**5 columnas**
Tipo de vivienda	**6 columnas**
Línea de negocio	**2 columnas**

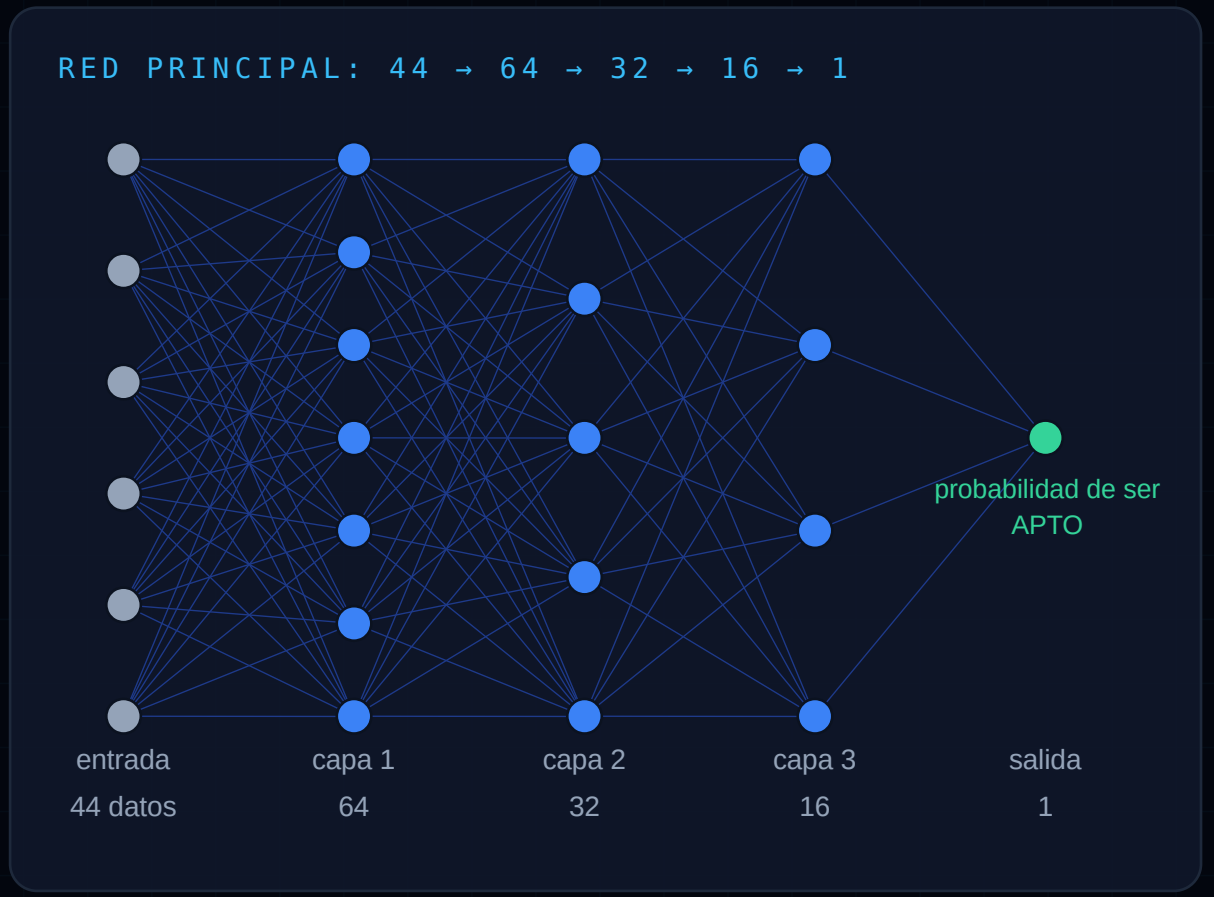
Ejemplo: una persona casada

Unión libre	Casado	Separado	Soltero	Viudo
0	1	0	0	0

Si numeráramos 1, 2, 3…, la red creería que «viudo» es mayor que «casado».

Cómo aprende una red neuronal

Una red neuronal es un conjunto de pequeñas calculadoras (neuronas) organizadas en capas. Cada conexión tiene un número llamado «peso». Aprender significa ajustar esos pesos hasta equivocarse lo menos posible.



1 — Predice

Toma 128 clientes y calcula una probabilidad para cada uno.

2 — Mide el error

Compara cada probabilidad con la respuesta real.

3 — Busca responsables

Calcula cuánto contribuyó cada peso a ese error (retropropagación).

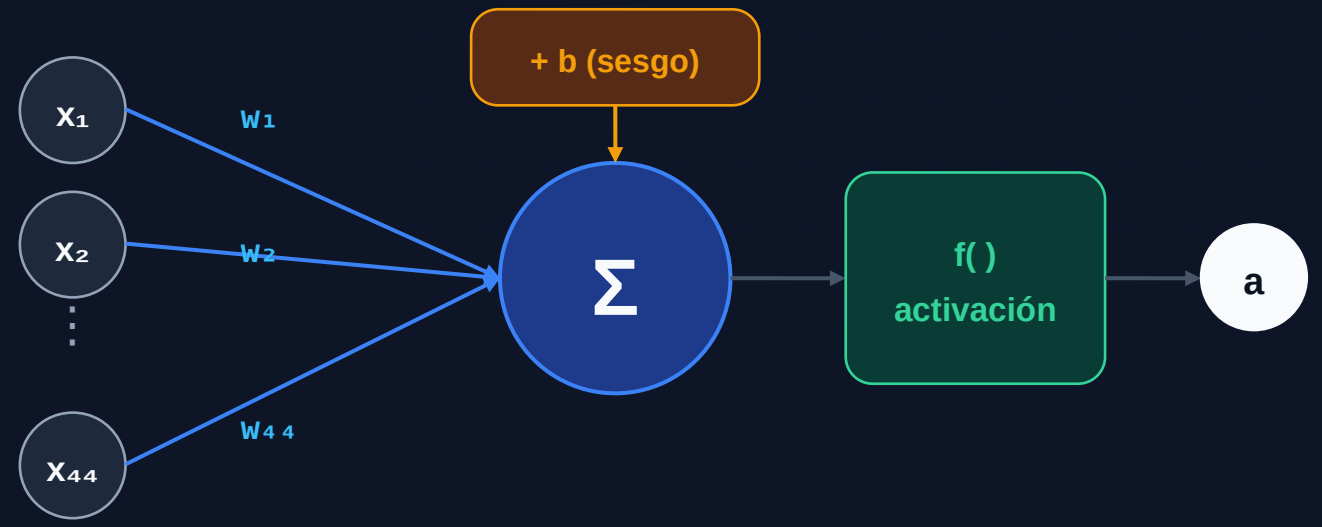
4 — Corrige

El optimizador Adam mueve cada peso un poco para equivocarse menos.

Estos cuatro pasos se repiten 272 veces por cada vuelta completa a los 34.755 clientes (una «época»).

Partes de una neurona: pesos, sesgo y función de activación

Todas las neuronas de la red funcionan igual: reciben números, los combinan con sus pesos y su sesgo, y aplican una función de activación. Esta es una neurona vista de cerca:



$$\text{salida} = f(\ w_1 \cdot x_1 + w_2 \cdot x_2 + \ldots + w_{44} \cdot x_{44} + b\ )$$

Ejemplo con 2 entradas: x = (0,5 ; −1,2), w = (0,8 ; 0,3), b = 0,1 → 0,8·0,5 + 0,3·(−1,2) + 0,1 = 0,14 → ReLU(0,14) = 0,14

Pesos (w)

Indican qué tan importante es cada dato para esa neurona. Pueden ser positivos (empujan hacia arriba) o negativos. La Red 1 tiene 5.392 pesos.

Sesgo (b)

Un número propio de cada neurona que se suma al final. Le permite activarse aunque las entradas sean 0, como el punto de partida de una recta. Hay un sesgo por neurona: 113 en la Red 1.

Función de activación f( )

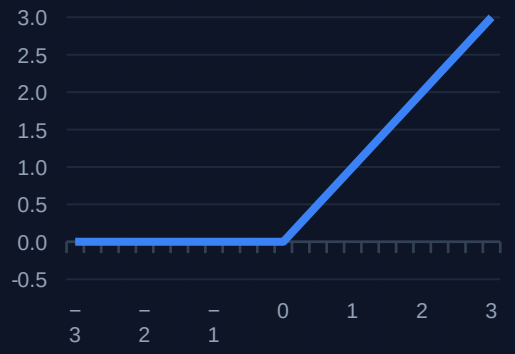
Decide cuánto se «enciende» la neurona con el total. Sin ella, la red entera solo podría aprender líneas rectas.

Funciones de activación utilizadas

La función de activación es el último paso de cada neurona: toma el total (pesos + sesgo) y decide cuánto se «enciende». En cada gráfica, el eje horizontal es ese total y el vertical lo que entrega la neurona.

ReLU

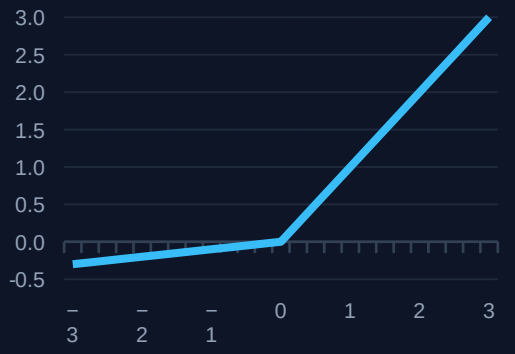
REDES 1 Y 3 (OCULTAS)



Deja pasar los valores positivos y convierte los negativos en 0. Es simple y rápida de entrenar.

LeakyReLU (α = 0,1)

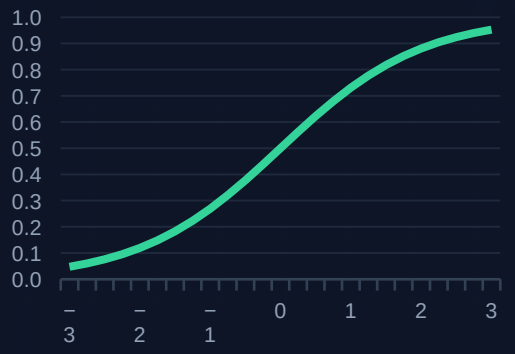
RED 2 (OCULTAS)



Igual que ReLU, pero deja pasar un 10 % de los negativos, para que ninguna neurona se «apague» del todo.

Sigmoide

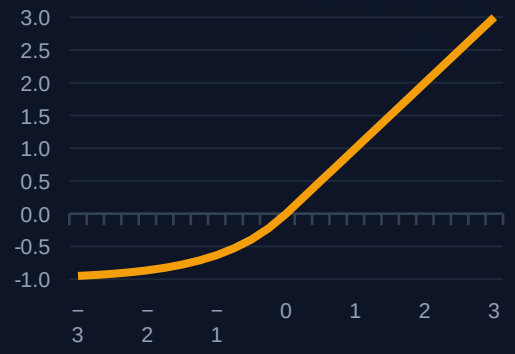
SALIDA DE LAS 3 REDES



Convierte el resultado final en una probabilidad entre 0 y 1. Si da 0,5 o más, el cliente es APTO.

ELU y GELU

PROBADAS EN FASE 3



Versiones «suaves» de ReLU. ELU fue la más estable entre semillas, pero ninguna superó al ensamble final.

Arquitectura completa de la Red 1

Recorrido de un cliente por la Red 1, capa por capa. Cada capa oculta tiene sus pesos, un sesgo por neurona y la función ReLU; la salida usa sigmoide para entregar la probabilidad.

ENTRADA

44 datos del cliente

Pesos	—
Sesgos	—
Activación	**ninguna**
Dropout	—

Los 44 números ya preparados (escalados y en 0/1).

CAPA OCULTA 1

64 neuronas

Pesos	**44 × 64 = 2.816**
Sesgos	**64**
Activación	**ReLU**
Dropout	**15 %**

Detecta combinaciones simples de los datos.

CAPA OCULTA 2

32 neuronas

Pesos	**64 × 32 = 2.048**
Sesgos	**32**
Activación	**ReLU**
Dropout	**15 %**

Combina lo que encontró la capa 1.

CAPA OCULTA 3

16 neuronas

Pesos	**32 × 16 = 512**
Sesgos	**16**
Activación	**ReLU**
Dropout	**no**

Resume todo en 16 señales de riesgo.

SALIDA

1 neurona

Pesos	**16 × 1 = 16**
Sesgos	**1**
Activación	**Sigmoide**
Dropout	**no**

Entrega la probabilidad de ser APTO (0 a 1).

Total: 5.392 pesos + 113 sesgos = 5.505 parámetros. Pesos iniciales con He (capas ReLU) y Glorot (salida); sesgos inician en 0.

Valores aprendidos: tras entrenar, los sesgos de la capa 1 quedaron entre −0,21 y 0,15, los pesos entre −0,79 y 0,73, y el sesgo de salida en −0,063.

Arquitectura de las Redes 2 y 3

Las otras dos redes del ensamble siguen la misma lógica (pesos + sesgo + activación en cada neurona), pero cambian en tamaño, activación o regularización.

Red 2 · LeakyReLU

1.936 pesos + 49 sesgos = 1.985 parámetros

Entrada	Oculta 1	Oculta 2	Salida
44	32	16	1
—	LeakyReLU · drop 15 %	LeakyReLU	Sigmoide

Por qué LeakyReLU: deja pasar un 10 % de los valores negativos, así ninguna neurona queda «apagada» para siempre. Además hace que esta red piense distinto a las otras dos.

Red 3 · ReLU

5.392 pesos + 113 sesgos = 5.505 parámetros

Entrada	Oculta 1	Oculta 2	Oculta 3	Salida
44	64	32	16	1
—	ReLU · drop 20 %	ReLU · drop 20 %	ReLU	Sigmoide

Misma forma que la Red 1, pero con más dropout (20 %), paso de aprendizaje de 0,001 y semilla 2026. Sus sesgos de la capa 1 quedaron entre −0,38 y 0,08.

Técnicas para evitar la memorización

Con miles de pesos, una red puede terminar aprendiéndose de memoria los clientes de entrenamiento en lugar de reglas generales. Para evitarlo se usaron cuatro técnicas:

Dropout

En cada paso de entrenamiento se apaga al azar el 15 % o 20 % de las neuronas.

Como estudiar en grupo donde cada día faltan compañeros distintos: todos deben entender el tema, nadie puede depender de otro.

Early Stopping (parada temprana)

Si en 12 épocas seguidas no mejora en validación, el entrenamiento se detiene y se recupera la mejor versión.

Como dejar de estudiar cuando los simulacros ya no suben, en vez de repetir hasta aprenderse las respuestas.

Reducción del paso de aprendizaje

Si la validación se estanca 5 épocas, el tamaño de cada corrección se reduce a la mitad.

Cuando se está cerca de la meta, se camina con pasos más cortos y cuidadosos.

Red compacta

Entre 1.985 y 5.505 pesos por red para 34.755 clientes (de 7 a 17 clientes por peso).

Con poca «memoria» disponible, a la red le toca encontrar reglas generales.

Ensamble de tres redes neuronales

El modelo final no es una sola red. Son tres redes diferentes que evalúan al mismo cliente por separado; luego se promedian sus tres probabilidades y con ese promedio se toma la decisión. Funciona como un comité de tres evaluadores.



Cada red tiene el mismo voto (1/3). En total el ensamble suma 12.995 pesos.

Diferencias entre las tres redes

Las tres redes se eligieron a propósito para que fueran diferentes. Si fueran iguales, cometerían los mismos errores y promediarlas no serviría de nada.

Característica	Red 1	Red 2	Red 3
Neuronas por capa	64 → 32 → 16	32 → 16	64 → 32 → 16
Número de pesos	5.505	1.985	5.505
Función de activación	ReLU	LeakyReLU	ReLU
Dropout (neuronas apagadas)	15 %	15 %	20 %
Tamaño del paso (learning rate)	0,0005	0,0005	0,001
Semilla (punto de partida)	42	42	2026
AUC sola en validación	0,7523	0,7522	0,7512
Qué aporta al comité	La base: tamaño medio y regularización suave	Otra forma de pensar: más pequeña y otra activación	Otro punto de partida y más dropout

Cómo vota el ensamble

Las tres redes coinciden en la mayoría de los clientes. La ventaja aparece en los casos dudosos: cuando una red se equivoca, las otras dos pueden corregirla.

EJEMPLO ILUSTRATIVO

Cliente A

Red 1	Red 2	Red 3	Promedio
0,62	0,48	0,57	0,557 → APTO

La Red 2 sola lo habría rechazado; el comité la corrige.

Cliente B

Red 1	Red 2	Red 3	Promedio
0,41	0,46	0,39	0,420 → NO APTO

Las tres coinciden: el promedio confirma la decisión.



Repetir la misma red con otras semillas casi no mejora. Combinar redes diferentes sí: sus predicciones coinciden en ~97 % (correlación 0,965–0,970) y en el resto se corrigen entre sí.

03 · EXPERIMENTACIÓN

Experimentos realizados

Cada decisión se tomó comparando varias pruebas, siempre con el grupo de validación.

Cantidad de pruebas realizadas

En total se entrenaron 164 redes neuronales y se evaluaron 19 combinaciones (ensambles). Cada configuración importante se repitió con 5 semillas distintas para comprobar que su resultado no dependía de la suerte.



164 redes neuronales entrenadas

19 combinaciones (ensambles) evaluadas

5 semillas por configuración clave: 42, 1, 7, 21 y 2026

1 sola vez se usó el grupo de prueba

Qué se buscó en cada etapa

Cada etapa respondió una pregunta y partió de lo mejor de la anterior. La nota que se usó para comparar es el AUC en validación (0,5 = adivinar al azar; 1 = perfecto).

Línea base

PREGUNTA

¿Cuánto logra una red razonable sin afinar?

RESULTADO

Red 64 → 32 → 16 con ReLU. Sirve de punto de comparación.

AUC val. 0,7497

Fase 1 · 37 pruebas

PREGUNTA

¿Qué tamaño de red, paso de aprendizaje, tamaño de lote y dropout funcionan mejor?

RESULTADO

Redes compactas, paso de 0,0005 y dropout de 15 %. Las grandes no mejoran.

AUC val. 0,7523

Fase 2 · 29 pruebas

PREGUNTA

¿Se puede afinar más? ¿Ayuda combinar redes?

RESULTADO

Ajuste fino de L2, dropout y paciencia. El ensamble de 3 redes distintas es el mejor.

AUC val. 0,7538

Fase 3 · 12 pruebas

PREGUNTA

¿Activaciones más modernas (ELU, GELU) o pesos distintos en el ensamble lo superan?

RESULTADO

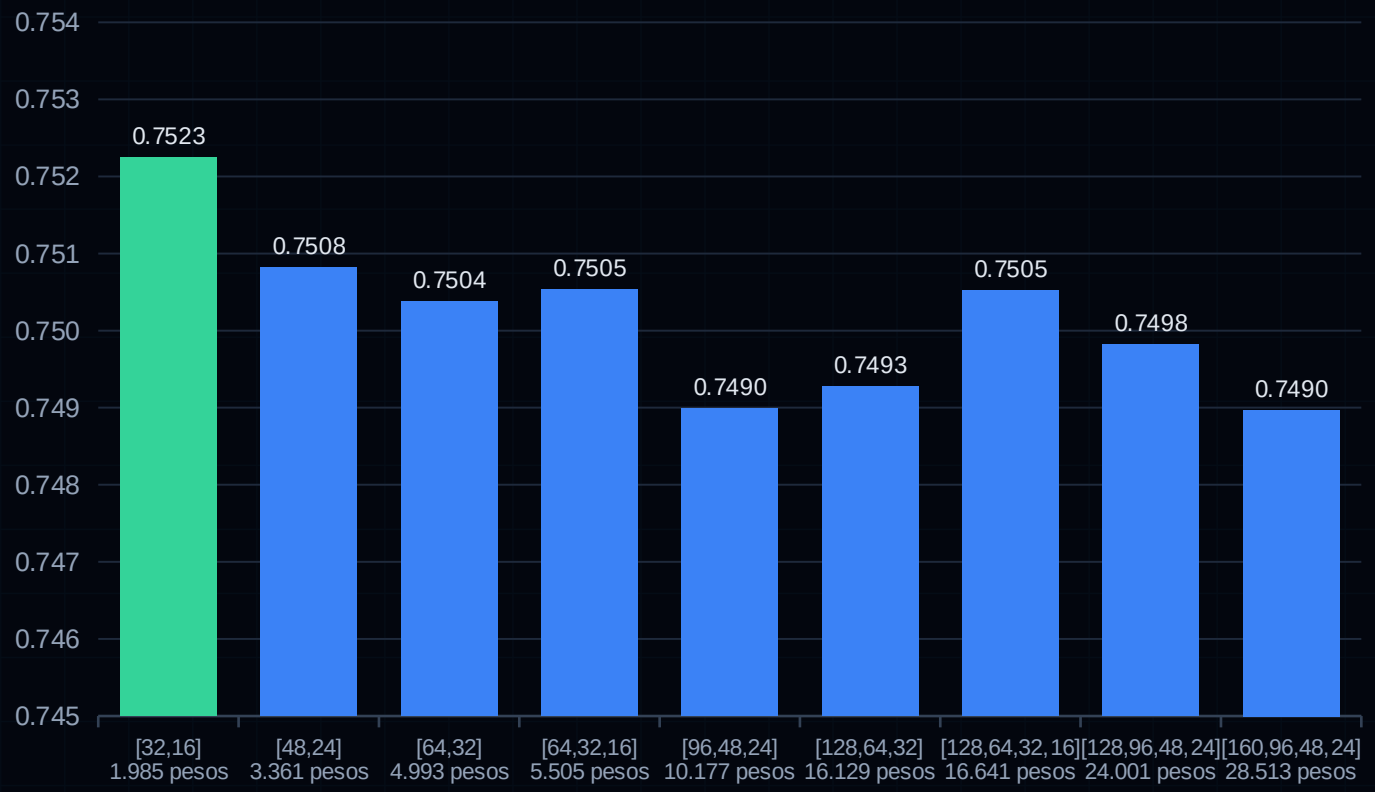
No lo superan: empatan. Se mantiene el ensamble de 3 redes.

AUC val. 0,7536

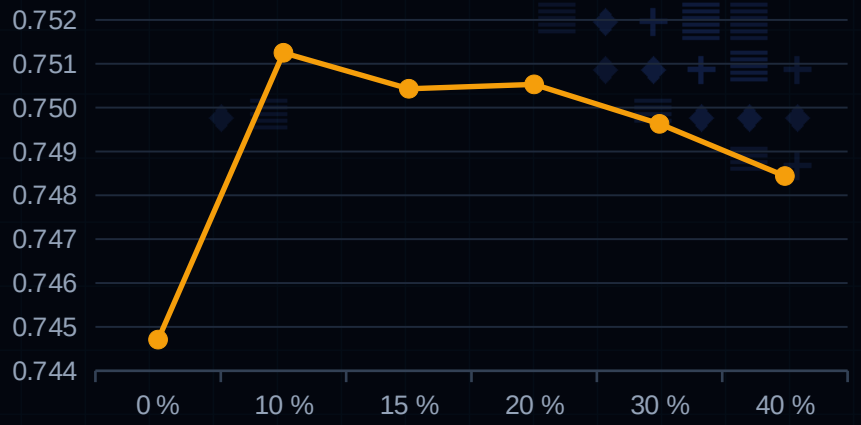
Resultados de la exploración inicial (fase 1)

En la fase 1 se cambió un solo factor a la vez para saber qué efecto tenía cada uno. Dos resultados importantes: las redes grandes no mejoraron y quitar el dropout empeoró el resultado.

AUC según el tamaño de la red (neuronas por capa)



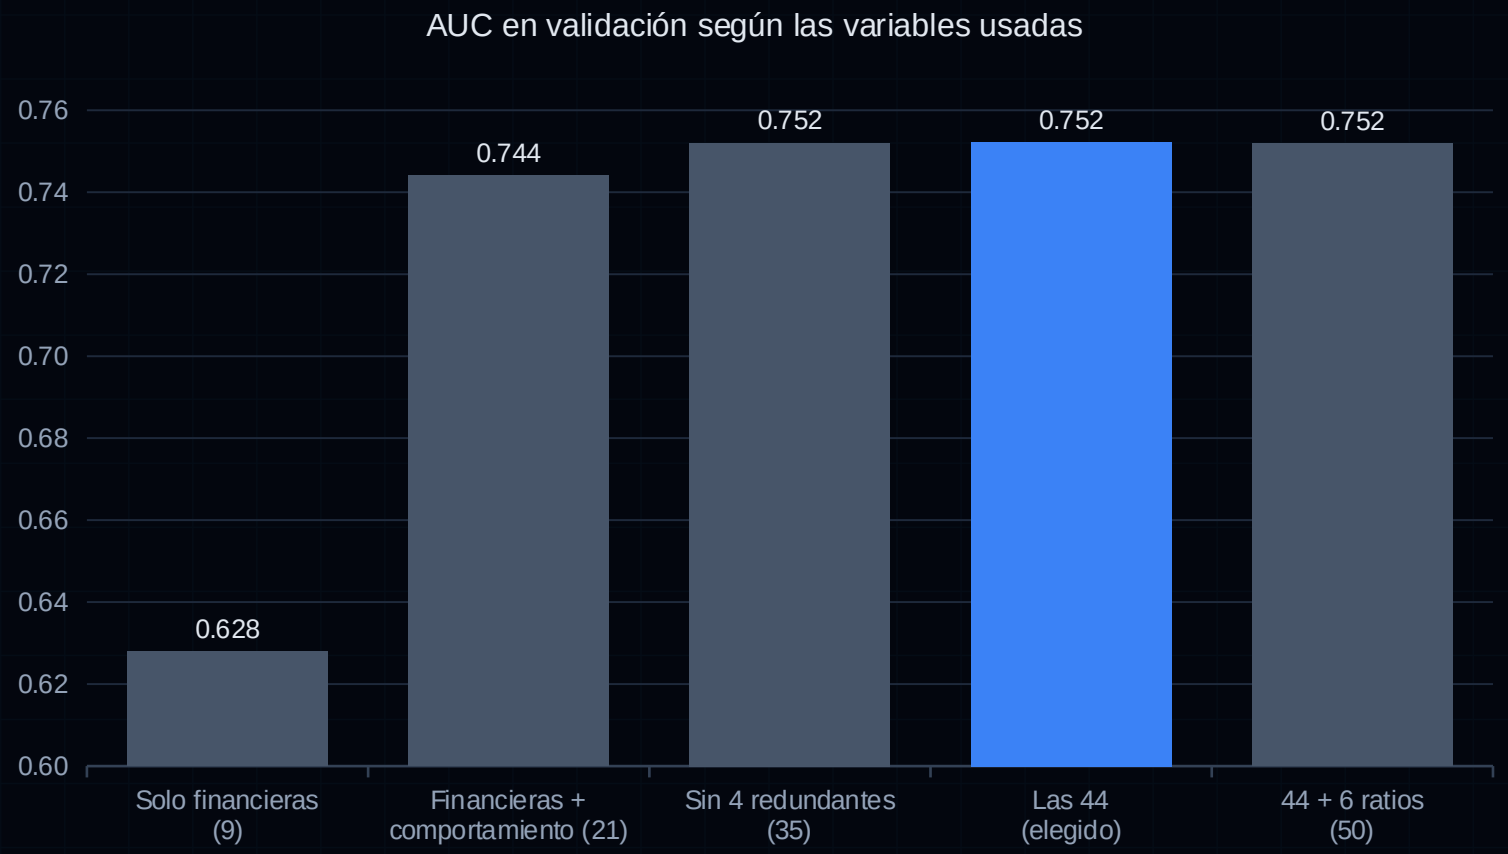
AUC según el dropout



- Más pesos no dan mejor resultado: solo más capacidad de memorizar
- Sin dropout: el peor resultado (0,7447)
- Batch Normalization empeoró; paso ideal: 0,0005

Efecto de quitar o agregar variables (ablación)

El estudio de ablación entrena la misma red con distintos grupos de variables para comprobar si todas son necesarias o si sobran algunas.



CONCLUSIÓN

Las 44 variables dan el mejor resultado

Quitar información empeora mucho (con 9 variables cae a 0,628). Agregar 6 indicadores calculados a mano tampoco ayuda, porque la red ya aprende esas relaciones por sí sola.

0,628 → 0,752

de 9 a 44 variables

Número de épocas de entrenamiento

Una época es una vuelta completa a los 34.755 clientes de entrenamiento. No se fijó un número de épocas: se puso un máximo de 100 y la parada temprana decidió cuándo detenerse según la validación.

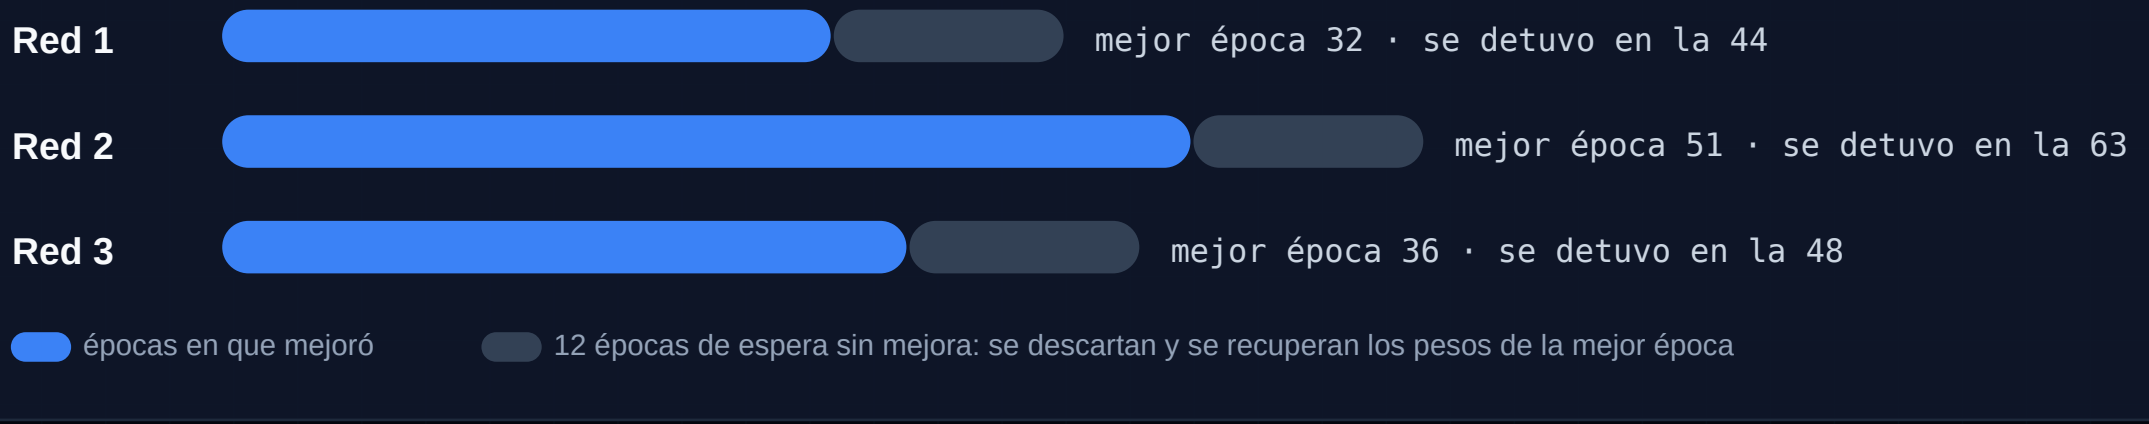
1 época
= una vuelta completa a los 34.755 clientes

272
correcciones de pesos por época (lotes de 128 clientes)

100
épocas como máximo permitido

41
épocas en promedio (mediana de 78 pruebas de diseño)

REDES DEL MODELO FINAL: MEJOR ÉPOCA Y ÉPOCAS ENTRENADAS



04 · APRENDIZAJE

Aprendizaje o memorización

Cinco pruebas para comprobar si el modelo aprendió patrones generales o solo memorizó los ejemplos.

Cómo leer una curva de aprendizaje

Una curva de aprendizaje muestra el error en cada época. La línea azul es el error con los clientes de entrenamiento (lo que la red estudia) y la naranja con los de validación (clientes que no estudia). Más bajo es mejor.

Un modelo que aprende

Las dos curvas bajan juntas y quedan cerca: lo aprendido sirve también para clientes nuevos.



Un modelo que memoriza

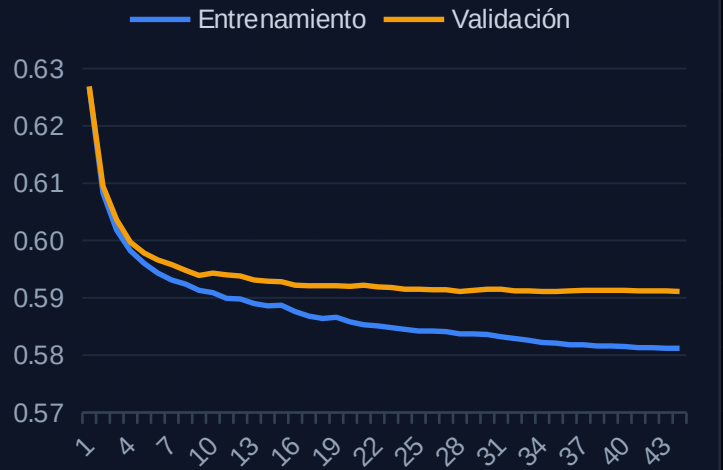
El error en entrenamiento baja casi a cero, pero en validación sube: se aprendió los ejemplos, no las reglas.



Ilustración conceptual (no son datos del proyecto).

CrediRisk

Prueba 1: curvas de las tres redes del modelo final







QUÉ HICIMOS

Se volvieron a entrenar las 3 redes del modelo final con su misma configuración y se anotó el error en cada época, tanto con los clientes de entrenamiento como con los de validación.

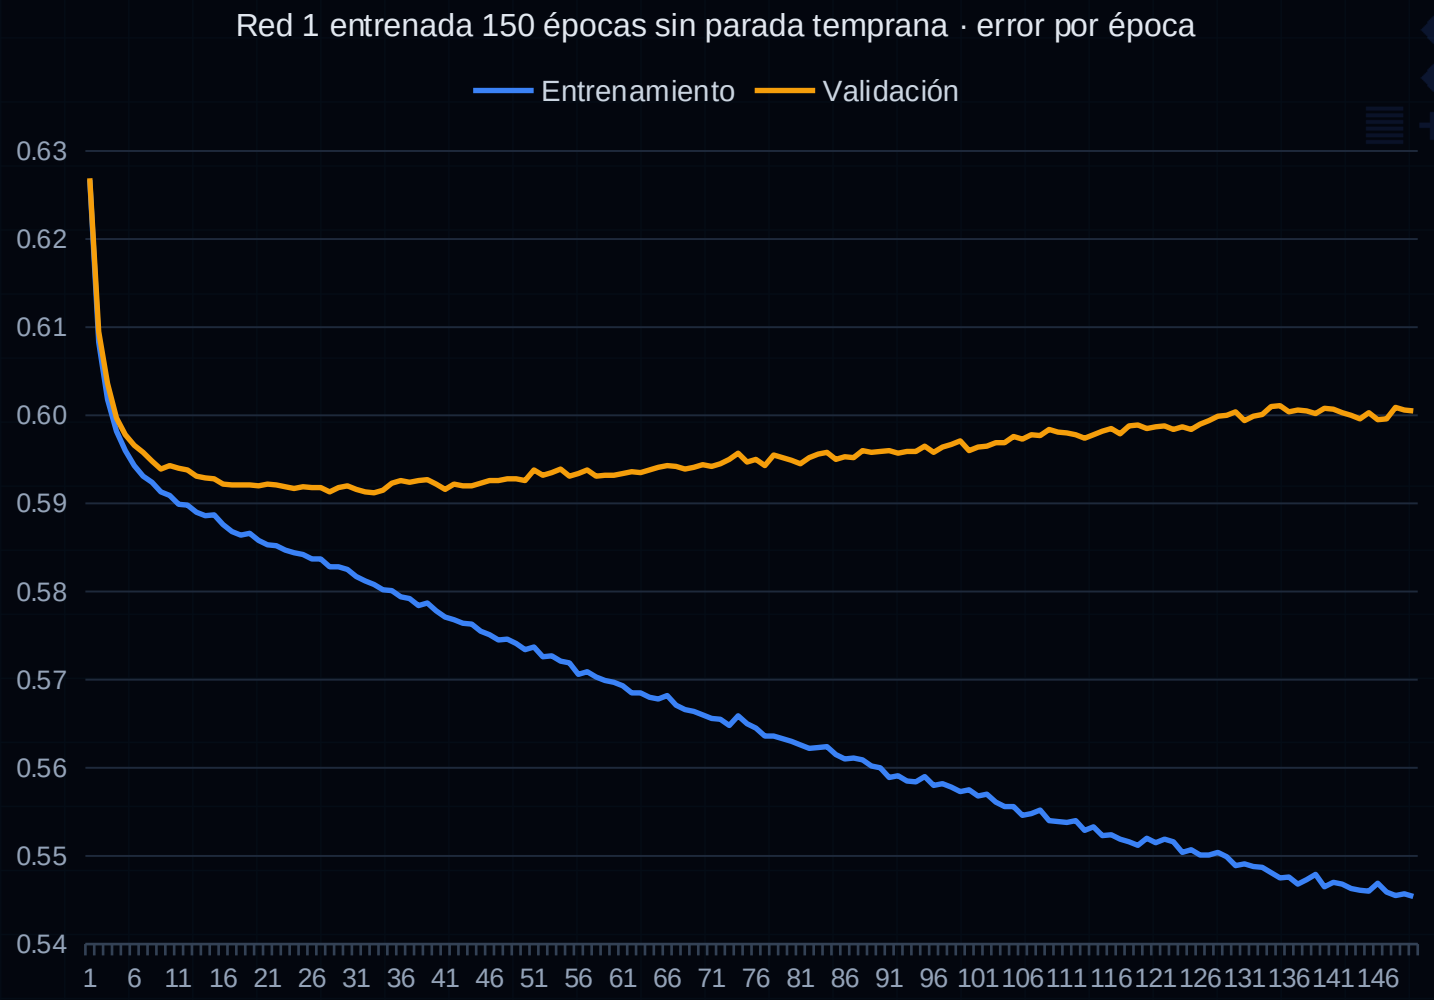
QUÉ BUSCÁBAMOS

Si la red memorizara, la línea azul seguiría bajando y la naranja empezaría a subir: las curvas se abrirían como una tijera.

QUÉ ENCONTRAMOS

Las dos curvas bajan juntas y se mantienen cerca. En la mejor época la diferencia de error es de solo 0,008 a 0,015.

Prueba 2: entrenamiento sin parada temprana



QUÉ HICIMOS

Se tomó la Red 1 y se dejó entrenar 150 épocas seguidas, sin parada temprana y sin reducir el paso de aprendizaje.

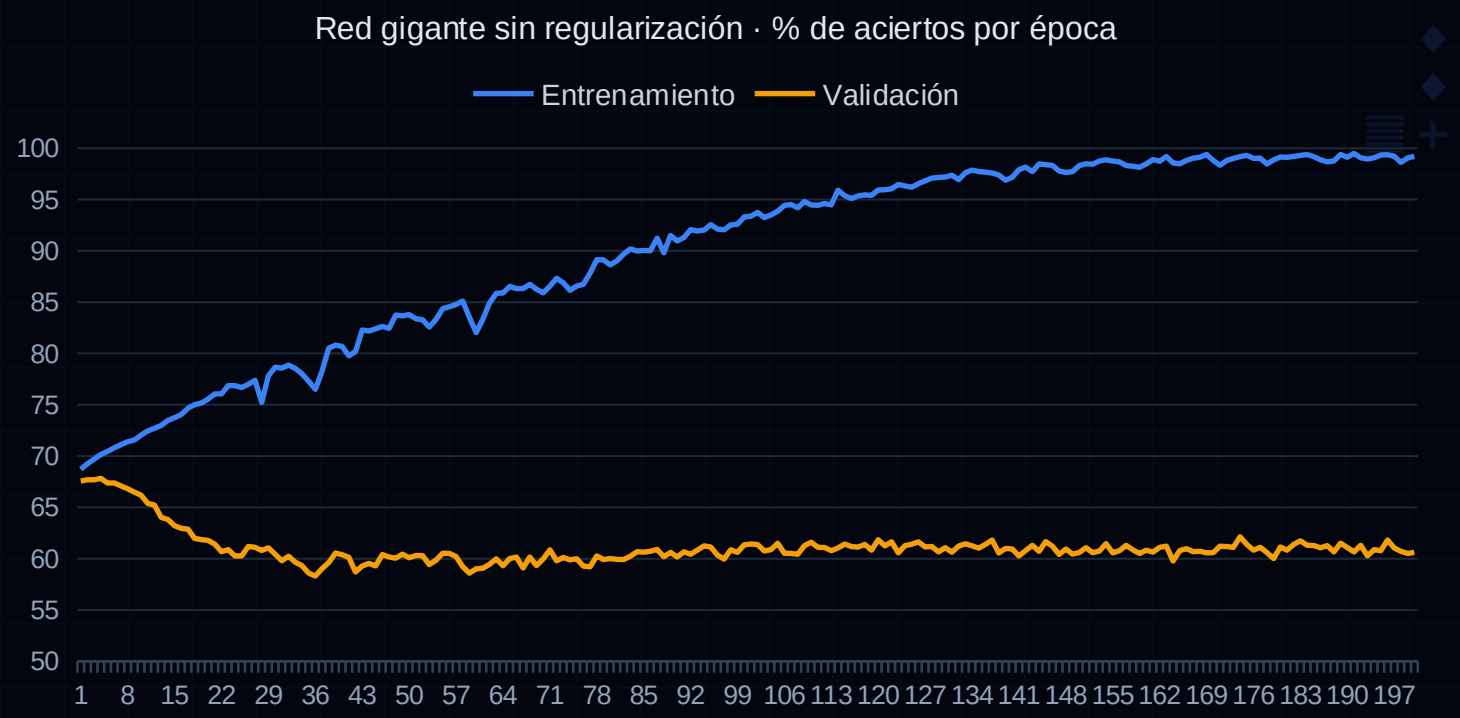
QUÉ BUSCÁBAMOS

Ver qué pasa si no se frena a tiempo: si la red empieza a memorizar al seguir entrenando.

QUÉ ENCONTRAMOS

Después de la época 44 (donde la parada temprana la detuvo), la validación empeora. Sin freno, la brecha sube a 0,027–0,059 y el AUC baja a 0,738–0,745; con freno es ≈ 0,752.

Prueba 3: comparación con una red que memoriza



Red gigante

187.393 pesos · sin técnicas

99,2 %	60,6 %
entrenamiento	validación

Nuestra Red 1

5.505 pesos · con técnicas

69,8 %	68,8 %
entrenamiento	validación

QUÉ HICIMOS

Se entrenó a propósito una red gigante [512, 256, 128] con 187.393 pesos (34 veces más que la nuestra), sin dropout, sin parada temprana y durante 200 épocas.

QUÉ BUSCÁBAMOS

Tener un ejemplo real de memorización para compararlo con nuestro modelo.

QUÉ ENCONTRAMOS

La gigante llega a 99,2 % de aciertos en entrenamiento pero solo 60,6 % en validación: memorizó. Nuestra Red 1 tiene 69,8 % y 68,8 %, casi iguales.

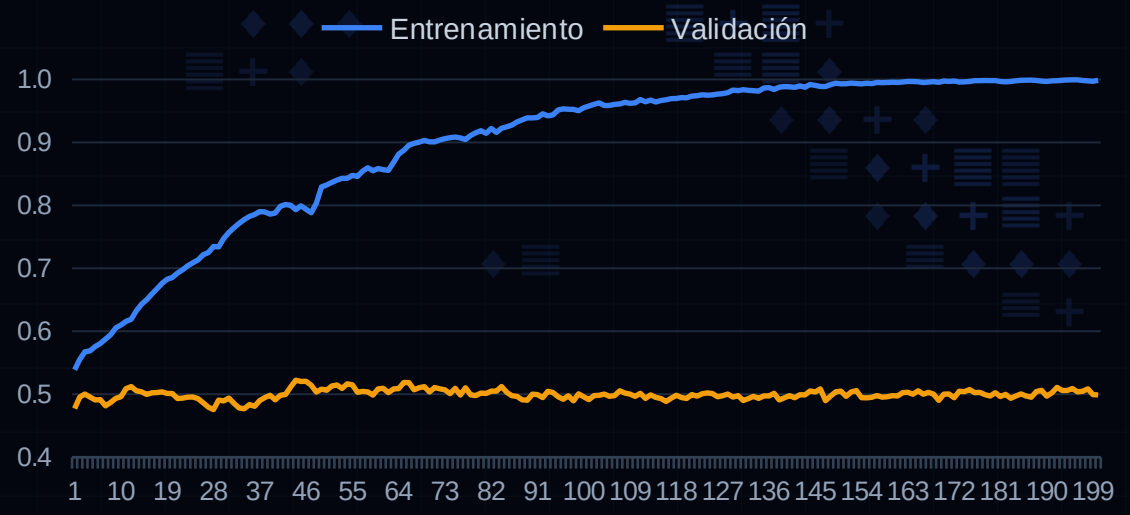
CrediRisk

Prueba 4: entrenamiento con respuestas al azar

Nuestra red con respuestas al azar · AUC por época



Red gigante con respuestas al azar · AUC por época



QUÉ HICIMOS

Se barajaron al azar las respuestas (APTO / NO APTO) de los clientes de entrenamiento. Así no queda ningún patrón real que aprender.

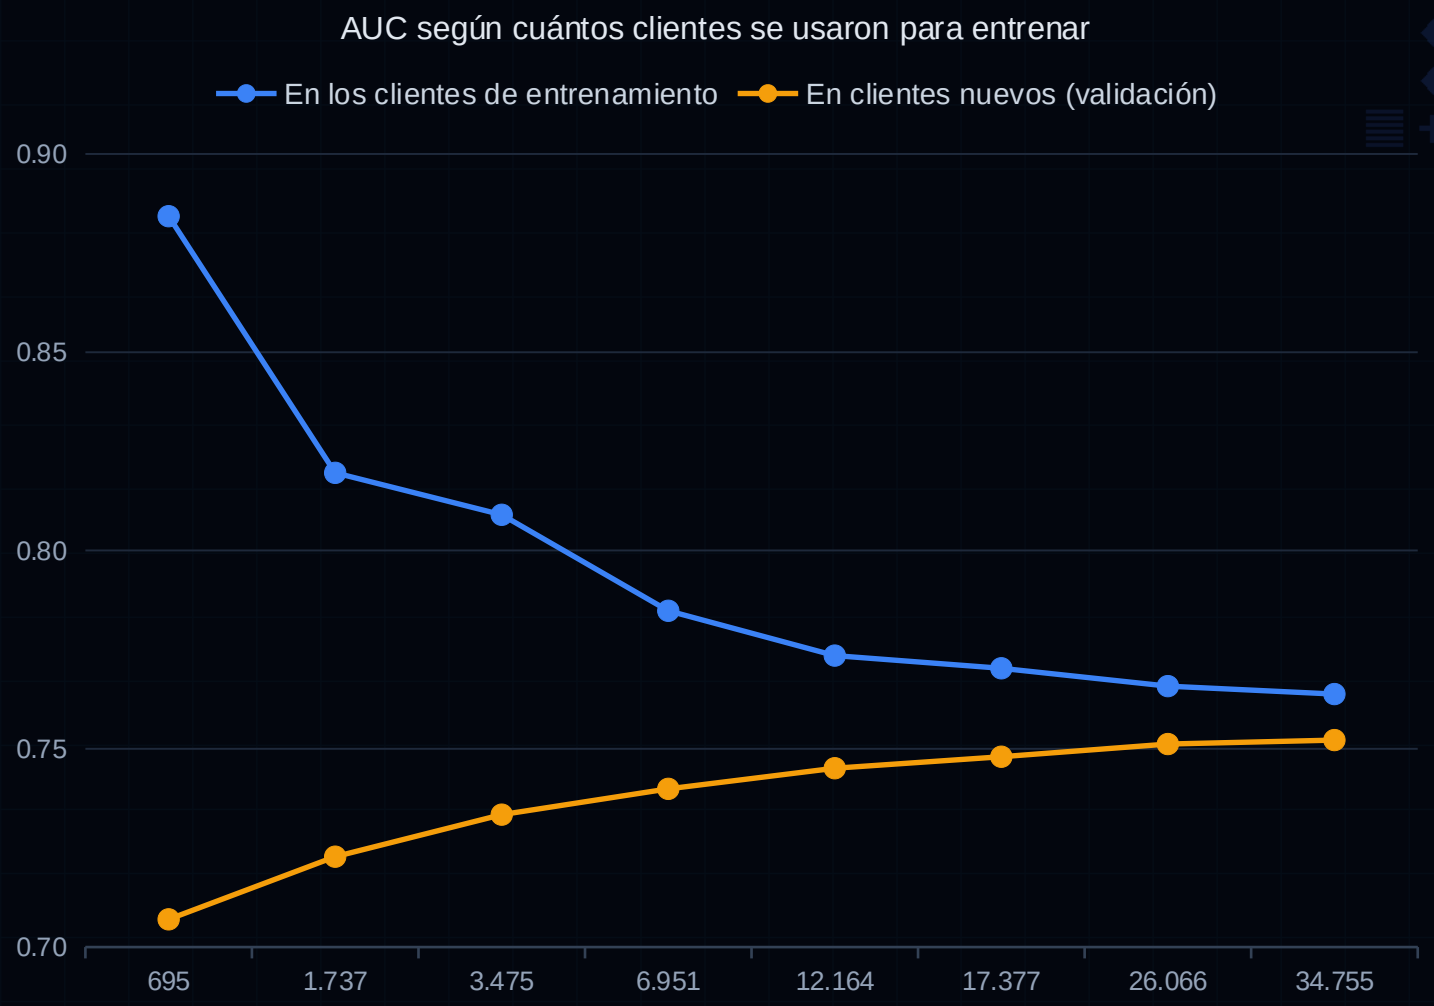
QUÉ BUSCÁBAMOS

Una red que memoriza también se aprendería esas respuestas falsas; una que busca patrones reales no debería lograr nada.

QUÉ ENCONTRAMOS

Nuestra red se queda en 0,50–0,54 (igual que adivinar) y se detiene sola. La gigante llega a 1,00 en entrenamiento y 0,50 en validación. Con las respuestas reales, la nuestra llega a 0,754.

Prueba 5: curva de aprendizaje según la cantidad de datos



QUÉ HICIMOS

Se entrenó la misma red usando el 2 %, 5 %, 10 %, 20 %, 35 %, 50 %, 75 % y 100 % de los clientes de entrenamiento.

QUÉ BUSCÁBAMOS

Comprobar si la diferencia entre lo estudiado y lo nuevo se reduce cuando hay más datos, como ocurre en un modelo que generaliza.

QUÉ ENCONTRAMOS

Con 695 clientes la brecha es de 0,177 (memoriza). Con los 34.755 baja a 0,012 y el AUC en clientes nuevos sube de 0,707 a 0,752.

Resumen de la evidencia

Las cinco pruebas, más la evaluación final en el grupo de prueba, apuntan a la misma conclusión: el modelo aprendió patrones generales y no memorizó los ejemplos.

Curvas juntas

Diferencia de error de 0,008 a 0,015 en la mejor época

Parada a tiempo

Se detuvo en las épocas 44 a 63, antes de que las curvas se separaran

Distinto a la red gigante

69,8 % vs 68,8 % de aciertos (la gigante: 99 % vs 61 %)

No aprende ruido

Con respuestas al azar se queda en 0,50

Más datos, menos brecha

La diferencia baja de 0,177 a 0,012

Clientes nunca vistos

AUC de 0,754 en validación a 0,745 en prueba (−1,2 %)

Aclaración: sí existe una diferencia pequeña entre los clientes de entrenamiento (AUC ≈ 0,768) y los nuevos (≈ 0,745). Es normal en cualquier modelo. La memorización se vería como en la red gigante, con diferencias enormes (99 % frente a 61 %).

05 · RESULTADOS

Resultados y medición del error

Evaluación final con 7.448 clientes que el modelo nunca vio, hecha una sola vez.

Cómo se mide el error (1): error en la decisión

La primera forma de medir el error es contar. Se toma la probabilidad de cada cliente, se decide APTO o NO APTO con el umbral de 50 % y se compara con lo que realmente pasó. Valores en el grupo de prueba (7.448 clientes):

Error de clasificación — 32,5 %

`fallos ÷ total`

`2.422 ÷ 7.448`

De cada 100 clientes, el modelo se equivoca con 32. Su complemento es la exactitud: 67,5 % de aciertos.

Precisión — 67,8 %

`aprobados correctos ÷ total de aprobados`

`2.476 ÷ 3.650`

De cada 100 clientes que el modelo aprueba, 68 eran realmente buenos pagadores.

Sensibilidad (recall) — 66,5 %

`buenos encontrados ÷ total de buenos`

`2.476 ÷ 3.724`

De cada 100 clientes buenos, el modelo encuentra y aprueba a 66.

F1 — 0,672

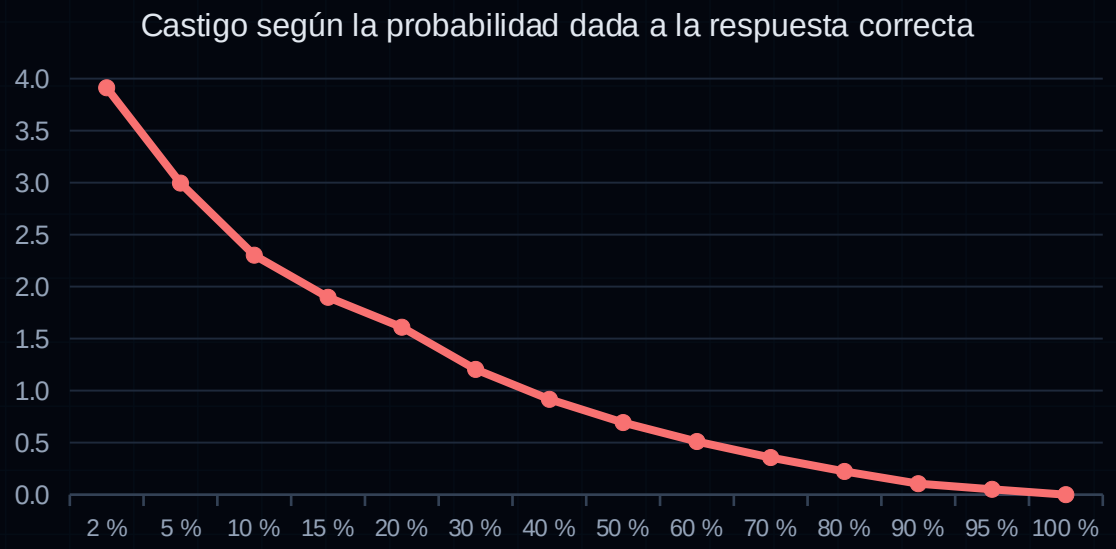
`equilibrio entre precisión y sensibilidad`

`promedio armónico`

Resume en un solo número qué tan bien acierta con los clientes buenos, sin favorecer una medida sobre otra.

Cómo se mide el error (2): error en la probabilidad

La segunda forma mide qué tan buena es la probabilidad, antes de decidir. Una red que dice «90 % seguro» y se equivoca debe recibir más castigo que una que dice «55 %» y se equivoca.



90 % y acierta	castigo 0,11
55 % y acierta	castigo 0,60
10 % (muy seguro y se equivoca)	castigo 2,30

Log loss (entropía cruzada) — **0,596**

Es el error que la red minimiza al entrenar: el promedio de los castigos. Si no supiera nada y dijera siempre 50 %, daría 0,693.

Brier — **0,205**

Promedio de (probabilidad − realidad)². Va de 0 (perfecto) a 0,25 (decir siempre 50 %).

AUC — **0,745**

Si se toma un cliente bueno y uno malo al azar, en 3 de cada 4 casos el modelo le da más probabilidad al bueno. No depende del umbral.

Resultados en el grupo de prueba

Resultados del modelo final en los 7.448 clientes del grupo de prueba, comparados con los de validación. La caída entre ambos es pequeña, lo que indica que el modelo generaliza.

0,745

AUC: ordena bien 3 de cada 4 parejas bueno/malo

67,5 %

de aciertos (5.026 de 7.448 clientes)

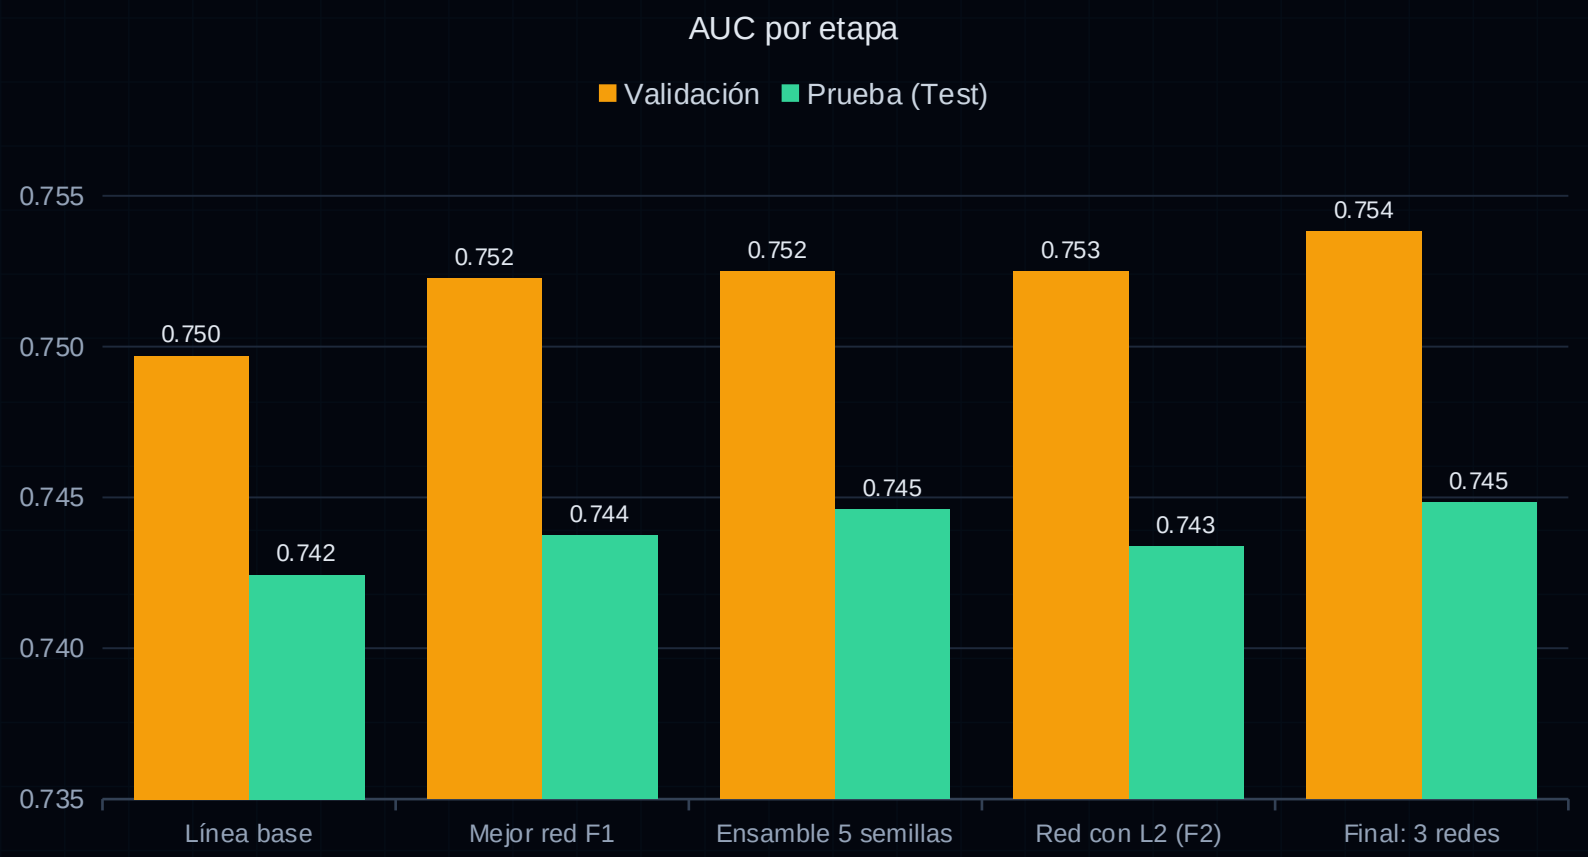
−1,2 %

de caída del AUC frente a validación



Evolución del AUC por etapa

Así cambió el AUC desde la línea base hasta el modelo final. La mejora es pequeña, pero aparece tanto en validación como en prueba.



MEJORA EN PRUEBA

+0,0024

de AUC frente a la línea base (0,7424 → 0,7448).

Es una mejora modesta. El aporte principal del proyecto es el método: sin fuga de datos, con pruebas para cada decisión y reproducible.

Aciertos y errores en el grupo de prueba

La matriz de confusión cruza lo que el modelo decidió con lo que realmente pasó. Las casillas verdes son aciertos y las rojas, errores.

	Predicho: NO APTO	Predicho: APTO
Real: NO APTO	**2.550** 34,2 % Verdaderos negativos: riesgosos bien rechazados	**1.174** 15,8 % Falsos positivos: riesgosos aprobados por error (el error más costoso)
Real: APTO	**1.248** 16,8 % Falsos negativos: buenos rechazados por error (negocio perdido)	**2.476** 33,2 % Verdaderos positivos: buenos bien aprobados

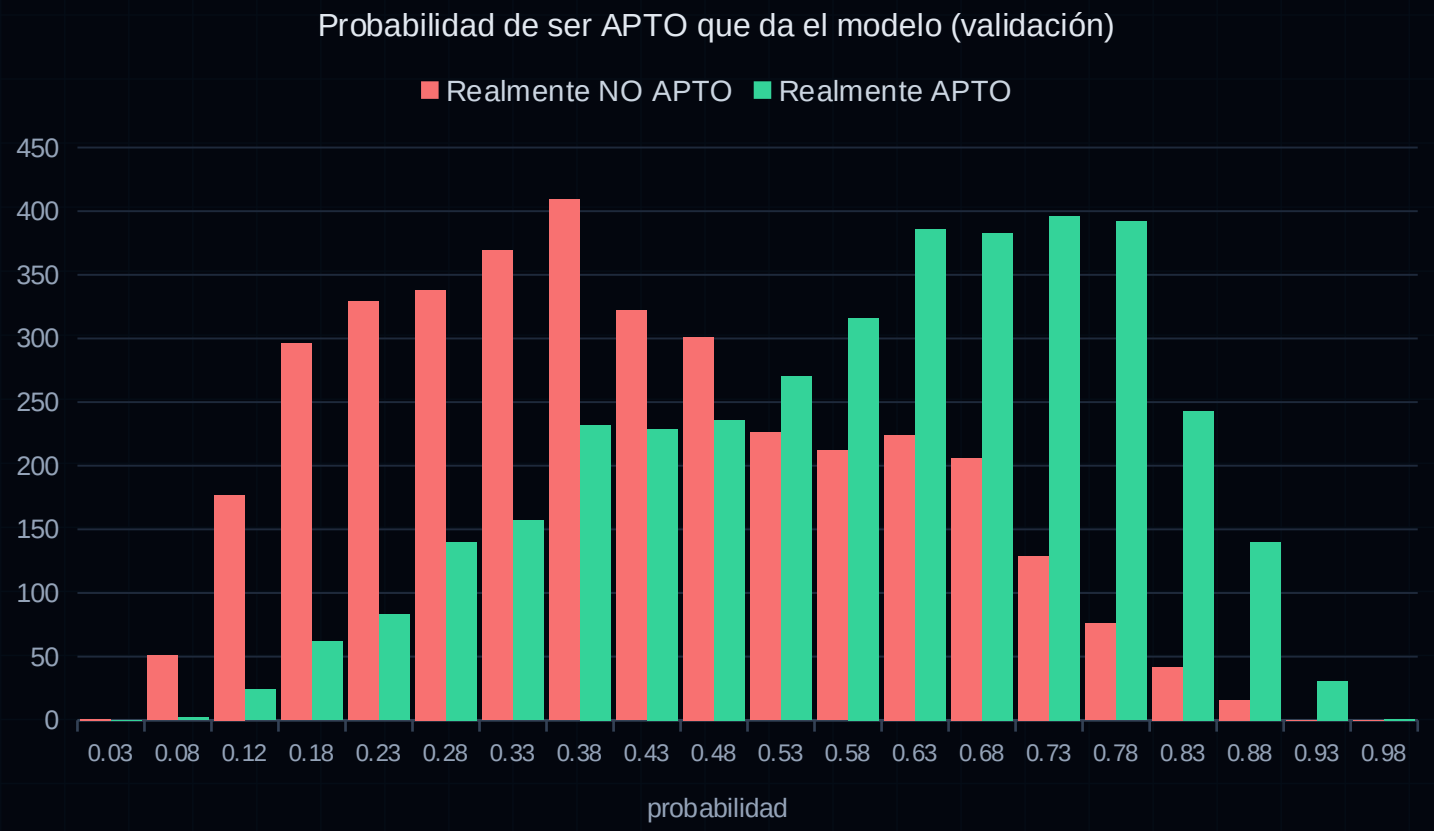
RESUMEN

5.026 aciertos y 2.422 errores

Los errores se reparten casi por igual entre los dos tipos. En un banco real, aprobar a quien no paga cuesta más que rechazar a un buen cliente; por eso el umbral de decisión se puede ajustar.

Por qué el modelo no acierta siempre

La gráfica muestra cuántos clientes reciben cada probabilidad, separados por lo que realmente pasó. Los errores ocurren en la zona central, donde clientes buenos y malos reciben probabilidades parecidas.



EXPLICACIÓN

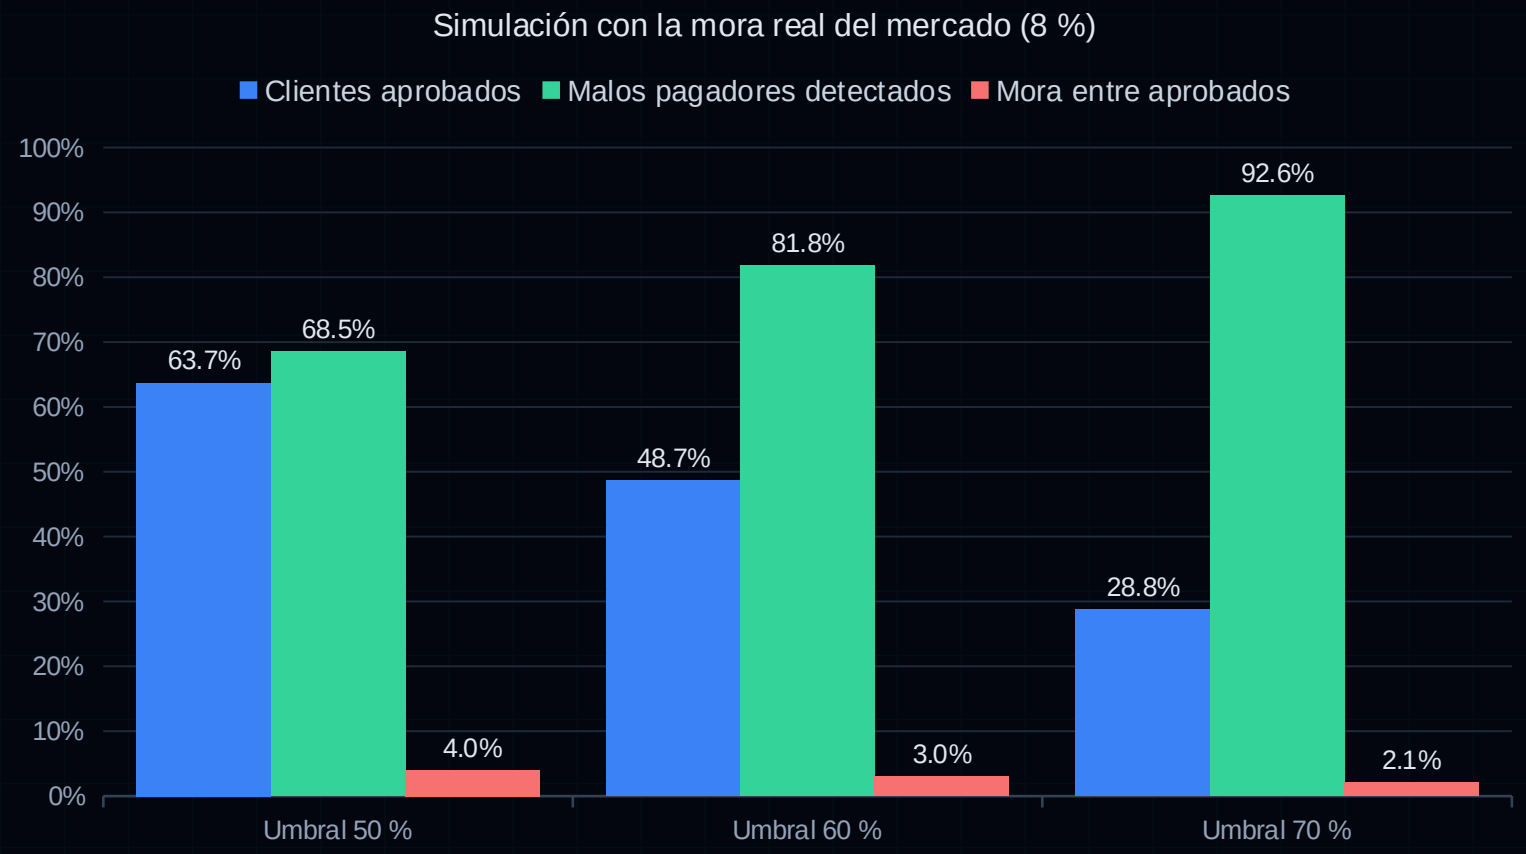
Hay muchas personas con datos casi idénticos: unas pagan y otras no, por causas que no aparecen en la base de datos (un despido, una enfermedad, una decisión personal).

Ningún modelo puede separar lo que los datos no distinguen. Más de 160 redes distintas llegaron al mismo límite de AUC (≈ 0,75).

Un 95 % de aciertos aquí sería señal de memorización o de fuga de datos.

Efecto del umbral de decisión

El umbral de 50 % es neutral. Un banco puede ser más exigente y aprobar solo si la probabilidad supera 60 % o 70 %. Simulación con la proporción real de mora del mercado (8 %):

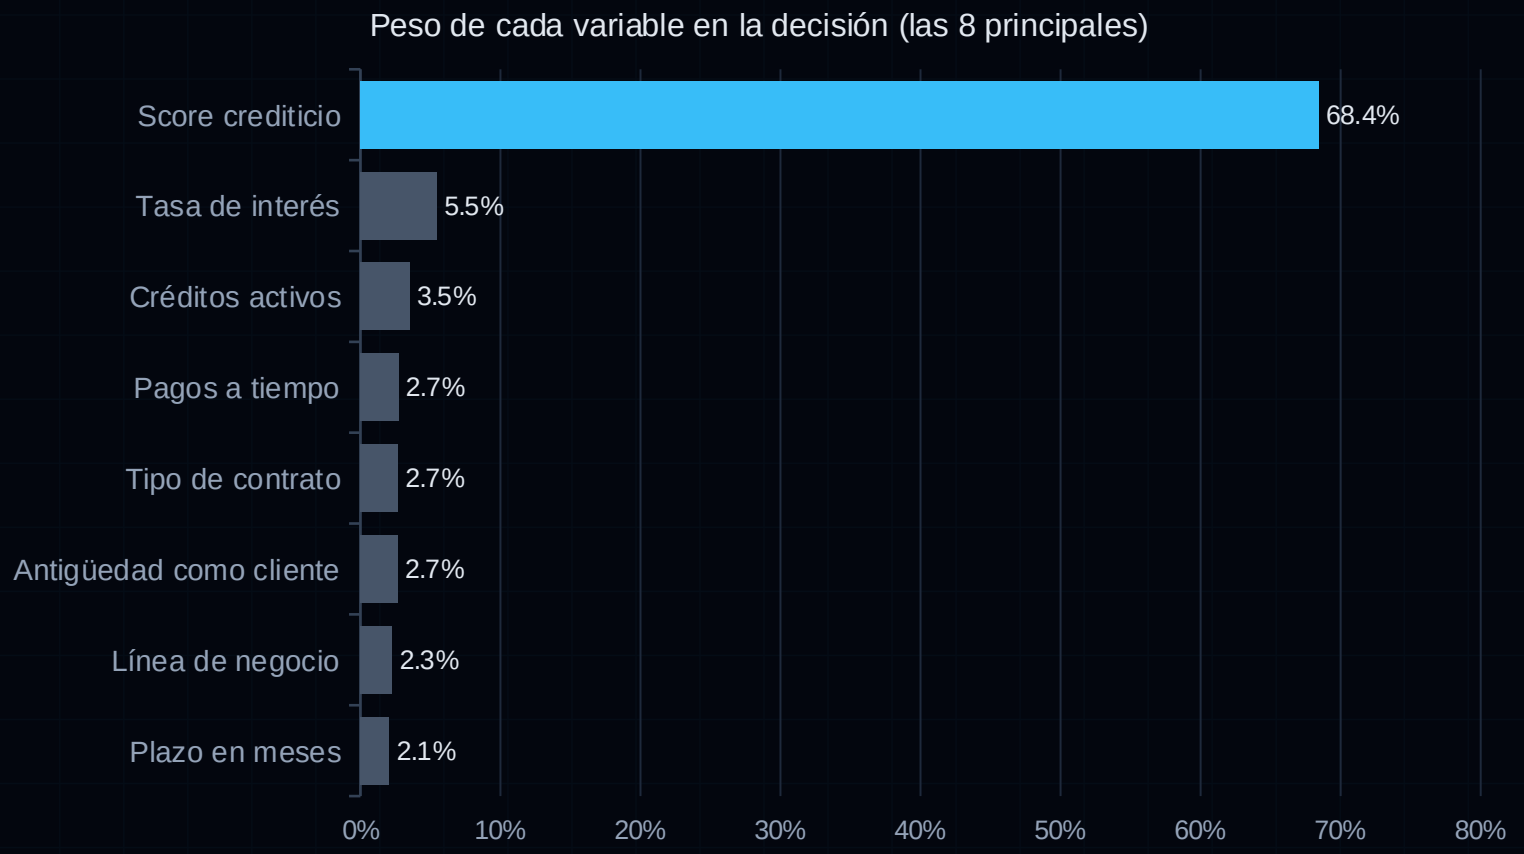


LECTURA

- Umbral 50 %: aprueba al 64 % de los clientes, con 4,0 % de mora
- Umbral 70 %: aprueba al 29 %, con 2,1 % de mora
- Más exigencia significa menos riesgo, pero también menos créditos otorgados
- La elección del umbral es una decisión del banco, no del modelo

Variables con más peso en la decisión

Para saber en qué se fija el modelo, se «revuelven» los valores de cada variable y se mide cuánto empeora el AUC. Mientras más empeora, más depende el modelo de esa variable.



68 %

del peso lo tiene el score crediticio

Tiene sentido: la forma en que una persona ha pagado antes es la mejor pista de cómo pagará después. Variables como tipo de vivienda o personas a cargo casi no influyen. Esto muestra asociación, no causa.

Limitaciones del estudio

Estas son las limitaciones del trabajo. Es importante tenerlas en cuenta al interpretar los resultados.

Mejora modesta

+0,0024 de AUC frente a la línea base, sin una prueba estadística formal que confirme que es significativa.

Una sola partición

Los resultados dependen de la división 70/15/15 con semilla 42; no se usó validación cruzada.

Solo redes MLP

No se compararon otros métodos como árboles de decisión o regresión logística.

Umbral neutral

El 50 % no refleja que un impago le cuesta al banco más que rechazar a un buen cliente.

Asociación, no causa

El modelo detecta relaciones en los datos, pero no explica por qué una persona deja de pagar.

Límite de los datos

Faltan causas reales del impago (despidos, salud) que no están en la base de datos.

Conclusiones

El modelo final es un ensamble de tres redes neuronales que alcanza un AUC de 0,745 en clientes que nunca vio.

1

Aprendió, no memorizó

Cinco pruebas lo confirman: curvas juntas, parada a tiempo, no aprende ruido y la brecha se cierra con más datos.

2

Decisiones con evidencia

164 redes y 19 combinaciones; cada cambio se comparó en validación y se repitió con 5 semillas.

3

Sin fuga de datos

Los datos se prepararon solo con entrenamiento y el grupo de prueba se usó una sola vez.

4

Resultado explicable

Ordena bien 3 de cada 4 parejas de clientes y se apoya sobre todo en el historial de pago.

PÁGINA WEB

suntzz.github.io/CrediRisk

Evaluador de crédito, laboratorio del modelo y todas las gráficas.

CrediRisk

Gracias por su atención

Preguntas y comentarios

Leidy Guecha · Sharick Hernández · Laura Díaz · Iván Solano · Cristian Martínez

suntzz.github.io/CrediRisk

Redes Neuronales Profundas · Universidad Católica de Colombia · 2026