CrediRisk

Evaluación del riesgo crediticio con un ensamble de redes neuronales profundas

Ensamble de 3 redes neuronales

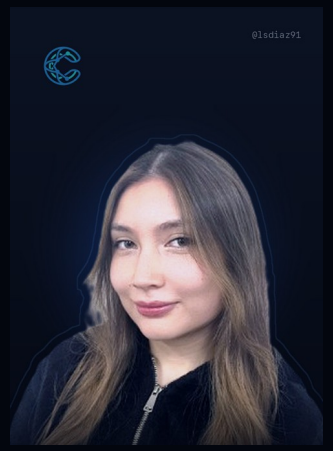
AUC 0,745 en clientes nunca vistos



Leidy Vanessa
Guecha Alape



Sharick Natalia
Hernández Gómez



Laura Sofía
Díaz Suárez



Iván Camilo
Solano Sánchez



Cristian Camilo
Martínez Delgado

Redes Neuronales Profundas · Universidad Católica de Colombia · 2026

El problema y los datos

QUÉ HACE EL MODELO

Recibe los datos de una solicitud de crédito de consumo y responde con una probabilidad de que la persona sea apta:

APTO (1)
probablemente pagará

NO APTO (0)
riesgo de no pagar

Regla: si la probabilidad es 50 % o más, el cliente es APTO.

49.650	23	50 / 50
solicitudes de crédito	datos por persona	aptos / no aptos

DIVISIÓN DE LOS DATOS (70 / 15 / 15)



Entrenamiento — 34.755 clientes

El «libro de ejercicios»: con estos la red aprende y ajusta sus pesos.

Validación — 7.447 clientes

Los «simulacros»: para comparar versiones y decidir cuándo parar.

Prueba (Test) — 7.448 clientes

El «examen final»: guardado sin tocar y usado una sola vez.

La división se hizo antes de cualquier cálculo y con la misma proporción de aptos en cada grupo: así la nota final es honesta.

Preparación de los datos: de 23 a 44 variables

PASO 1

Limpiar

Se quita el número de solicitud y la columna que era la respuesta disfrazada (sería hacer trampa).

PASO 2

Rellenar vacíos

Se usa el valor típico (mediana) y se agrega un aviso de que el dato faltaba.

PASO 3

Suavizar extremos

Ingresos y deudas muy grandes se recortan y se comprimen con logaritmo.

PASO 4

Traducir y escalar

Las categorías pasan a columnas 0/1 y todo queda en la misma escala.

19 numéricas + **7** avisos de dato faltante + **18** columnas de categorías = **44** entradas de la red

19 NUMÉRICAS → 19 COLUMNAS

Edad, ingresos, obligaciones, monto, plazo, cuota, tasa, endeudamiento, score, créditos activos, saldo, mora, pagos oportunos, antigüedad, patrimonio y personas a cargo. Cada una sigue siendo una columna.

7 AVISOS DE DATO FALTANTE

Las variables con más del 1 % de vacíos reciben una columna extra (0 = estaba, 1 = faltaba): saldo, créditos activos, antigüedad laboral y como cliente, pagos oportunos, obligaciones y cuotas en mora.

4 CATEGORÍAS → 18 COLUMNAS

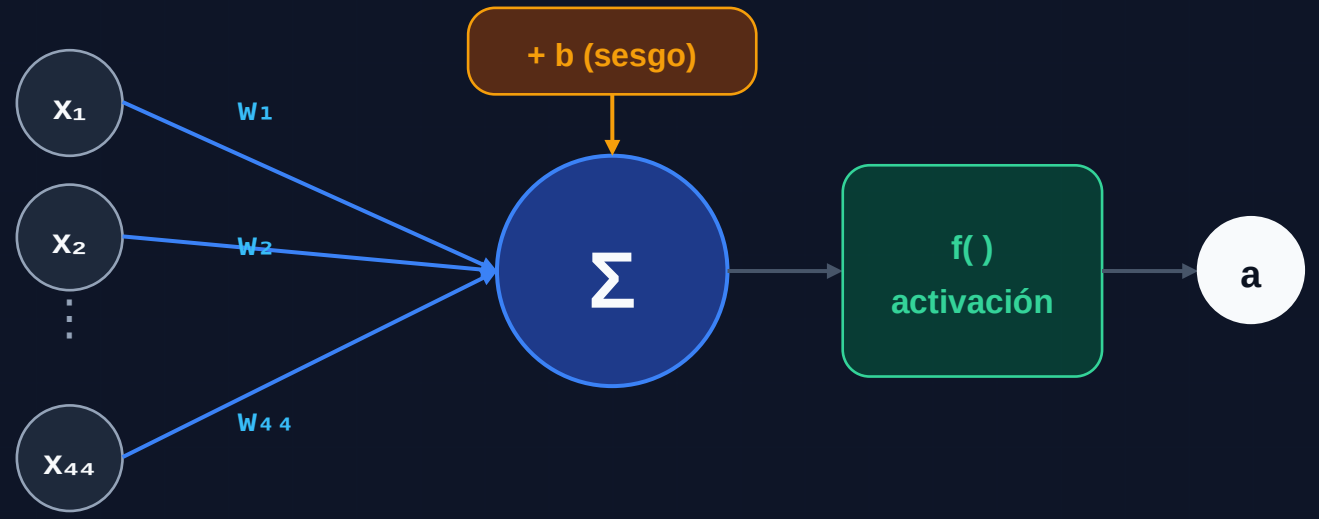
Estado civil 5 · Contrato 5 · Vivienda 6 · Negocio 2

Ejemplo, una persona casada:

U. libre	Casado	Separado	Soltero	Viudo
0	1	0	0	0

No se usan 1, 2, 3…: la red creería que una categoría es «mayor» que otra.

Cómo funciona y cómo aprende una neurona



$$\text{salida} = f(\ w_1 \cdot x_1 + w_2 \cdot x_2 + \ldots + w_{44} \cdot x_{44} + b\ )$$

Ejemplo: x = (0,5 ; −1,2), w = (0,8 ; 0,3), b = 0,1 → 0,4 − 0,36 + 0,1 = 0,14 → ReLU(0,14) = 0,14

Pesos (w)

Qué tan importante es cada dato para la neurona. Pueden ser positivos o negativos.

Sesgo (b)

Número propio de cada neurona que se suma al final; le permite activarse aunque las entradas sean 0.

Función de activación

Decide cuánto se «enciende» la neurona con ese total.

CÓMO APRENDE

1. **Predice**
2. **Mide el error**
3. **Busca responsables**
4. **Corrige los pesos**

272 veces por época (lotes de 128 clientes) · optimizador Adam

Arquitectura de las tres redes

RED 1 (PRINCIPAL) · 5.392 PESOS + 113 SESGOS = 5.505 PARÁMETROS

ENTRADA	OCULTA 1	OCULTA 2	OCULTA 3	SALIDA
44 datos	**64** neuronas	**32** neuronas	**16** neuronas	**1** neurona
Pesos —	Pesos 44 × 64 = 2.816	Pesos 64 × 32 = 2.048	Pesos 32 × 16 = 512	Pesos 16 × 1 = 16
Sesgos —	Sesgos 64	Sesgos 32	Sesgos 16	Sesgos 1
Activación —	Activación ReLU	Activación ReLU	Activación ReLU	Activación Sigmoide
Dropout —	Dropout 15 %	Dropout 15 %	Dropout no	Dropout no

Red 2 · LeakyReLU — 44 → 32 → 16 → 1

LeakyReLU en las ocultas · dropout 15 % solo en la 1.ª · sigmoide en la salida

`1.936 pesos + 49 sesgos = 1.985 parámetros`

Red 3 · ReLU — 44 → 64 → 32 → 16 → 1

ReLU en las ocultas · dropout 20 % · paso 0,001 · semilla 2026 · sigmoide en la salida

`5.392 pesos + 113 sesgos = 5.505 parámetros`

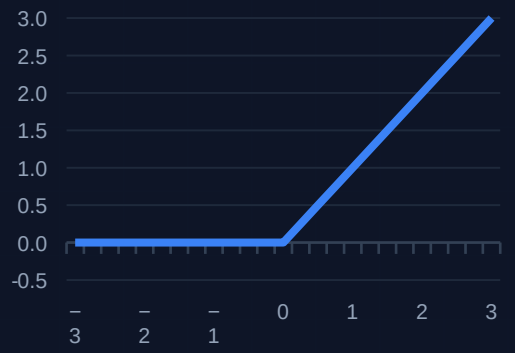
Pesos iniciales: He (capas ReLU) y Glorot (salida); sesgos inician en 0. Tras entrenar, los sesgos de la capa 1 de la Red 1 quedaron entre −0,21 y 0,15 y el de salida en −0,063.

Funciones de activación utilizadas y por qué

La función de activación es el último paso de cada neurona: toma el total (pesos + sesgo) y decide cuánto se «enciende». En cada gráfica, el eje horizontal es ese total y el vertical lo que entrega la neurona.

ReLU

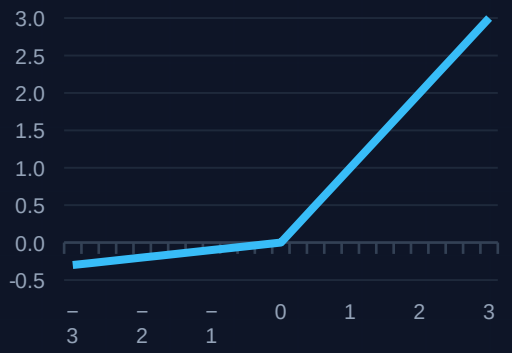
REDES 1 Y 3 (OCULTAS)



Deja pasar los valores positivos y convierte los negativos en 0. Por qué: es simple, rápida y no se «satura» en redes de varias capas.

LeakyReLU (α = 0,1)

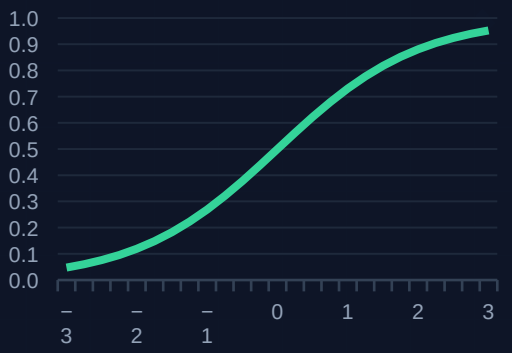
RED 2 (OCULTAS)



Como ReLU, pero deja pasar un 10 % de los negativos. Por qué: ninguna neurona se «apaga» del todo y la red piensa distinto a las otras.

Sigmoide

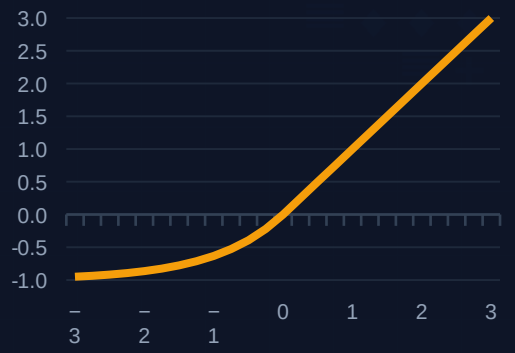
SALIDA DE LAS 3 REDES



Convierte el resultado en un número entre 0 y 1. Por qué: necesitamos una probabilidad para decidir APTO o NO APTO.

ELU y GELU

PROBADAS EN FASE 3



Versiones «suaves» de ReLU. ELU fue la más estable entre semillas, pero ninguna superó al ensamble final.

Técnicas contra la memorización y número de épocas

Dropout

Apaga al azar el 15–20 % de las neuronas en cada paso, para que la red no dependa de unas pocas.

Parada temprana

Si en 12 épocas no mejora en validación, se detiene y recupera su mejor versión.

Paso más corto

Si se estanca 5 épocas, el tamaño de cada corrección se reduce a la mitad.

Red compacta

Entre 1.985 y 5.505 parámetros para 34.755 clientes: poca «memoria» disponible.

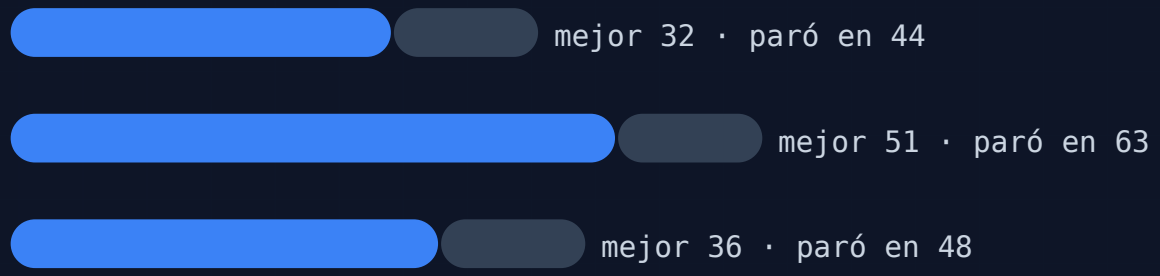
ÉPOCAS: UNA ÉPOCA = UNA VUELTA COMPLETA A LOS 34.755 CLIENTES

272 correcciones por época

100 épocas como máximo

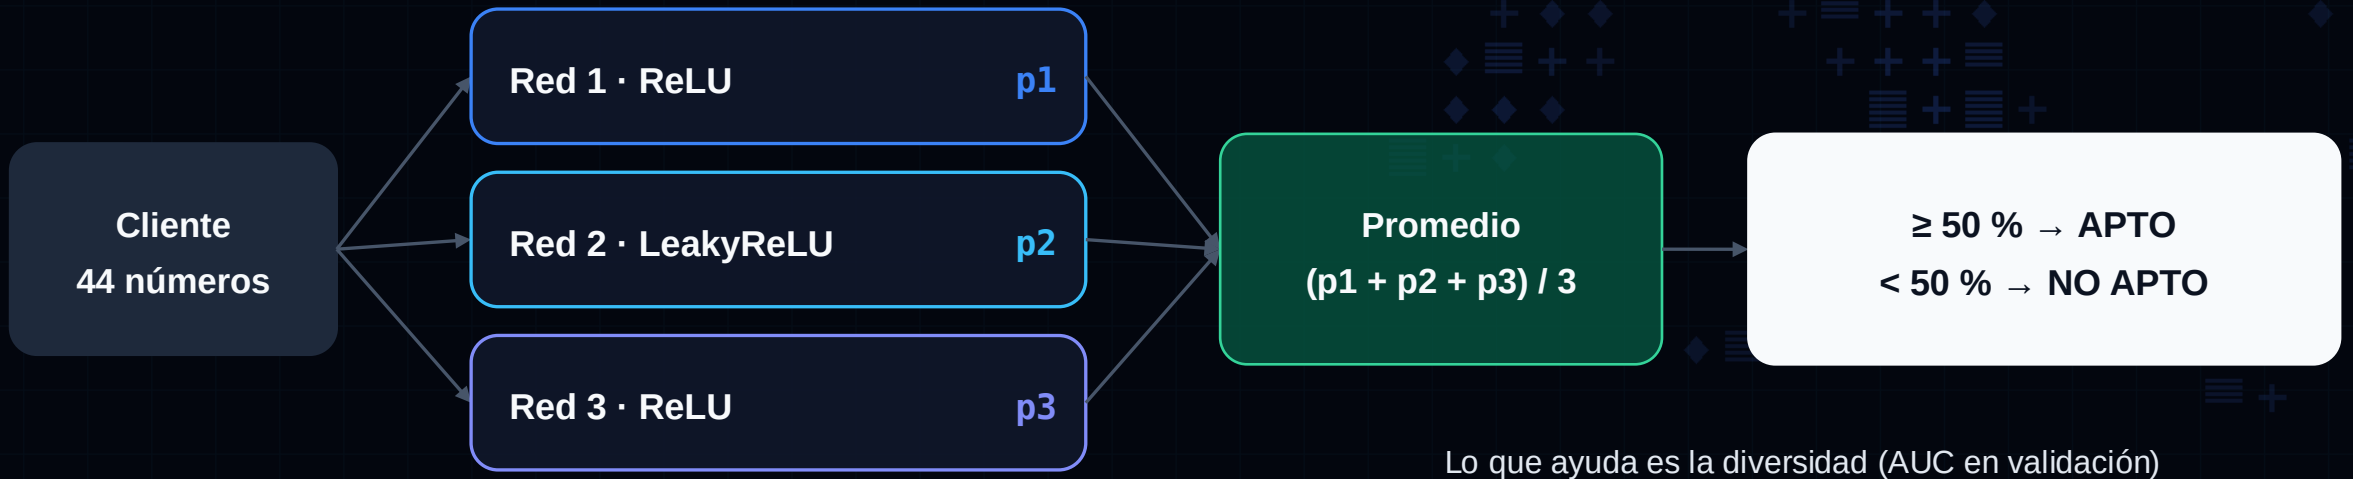
41 épocas en promedio (78 pruebas)

Redes del modelo final



Azul: épocas en que mejoró · gris: 12 épocas de espera sin mejora (se descartan).

Ensamble de tres redes

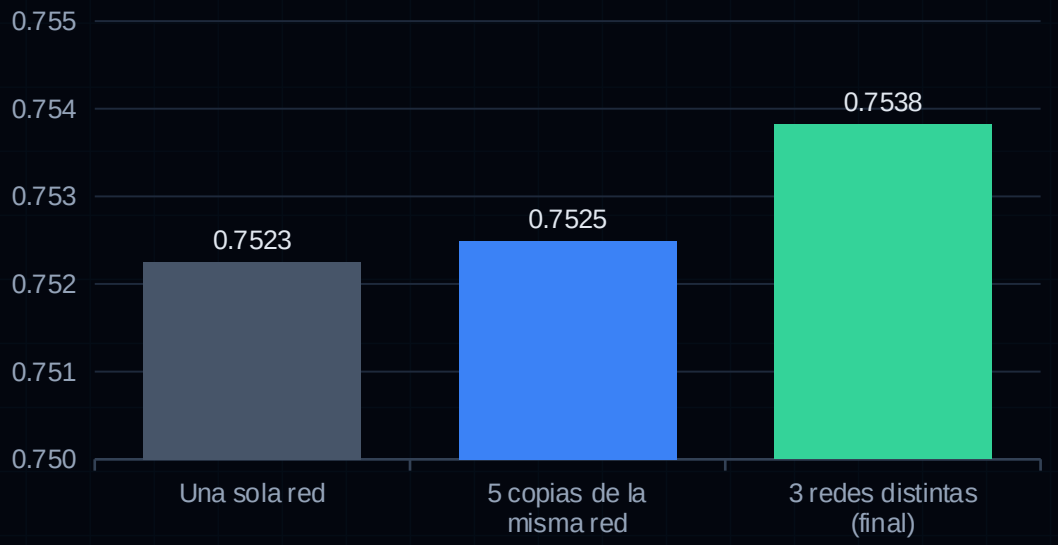


EJEMPLO ILUSTRATIVO

Red 1	Red 2	Red 3	Promedio
0,62	0,48	0,57	0,557 APTO

La Red 2 sola lo habría rechazado; las otras dos la corrigen. Cada red tiene el mismo voto (1/3).

Lo que ayuda es la diversidad (AUC en validación)



Pruebas realizadas por etapa

164	redes entrenadas
19	ensambles evaluados
5	semillas por configuración clave
1	sola vez se usó el grupo de prueba

Línea base · 5 redes

PREGUNTA

¿Cuánto logra una red razonable sin afinar?

RESULTADO

Red 64 → 32 → 16 con ReLU: punto de comparación.

AUC val. 0,7497

Fase 1 · 70 redes

PREGUNTA

¿Qué tamaño, paso de aprendizaje, lote y dropout funcionan mejor?

RESULTADO

Redes compactas, paso 0,0005 y dropout 15 %. Las grandes no mejoran.

AUC val. 0,7523

Fase 2 · 57 redes

PREGUNTA

¿Se puede afinar más? ¿Ayuda combinar redes?

RESULTADO

Ajuste fino de L2, dropout y paciencia. El ensamble de 3 redes distintas es el mejor.

AUC val. 0,7538

Fase 3 · 32 redes

PREGUNTA

¿Activaciones modernas (ELU, GELU) o pesos distintos lo superan?

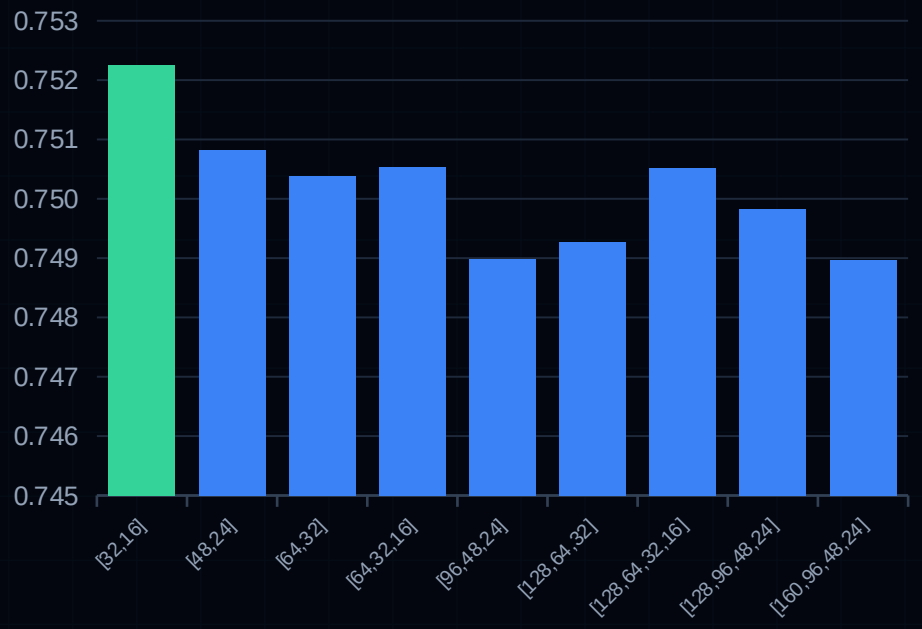
RESULTADO

Empatan, pero no lo superan. Se mantiene el ensamble.

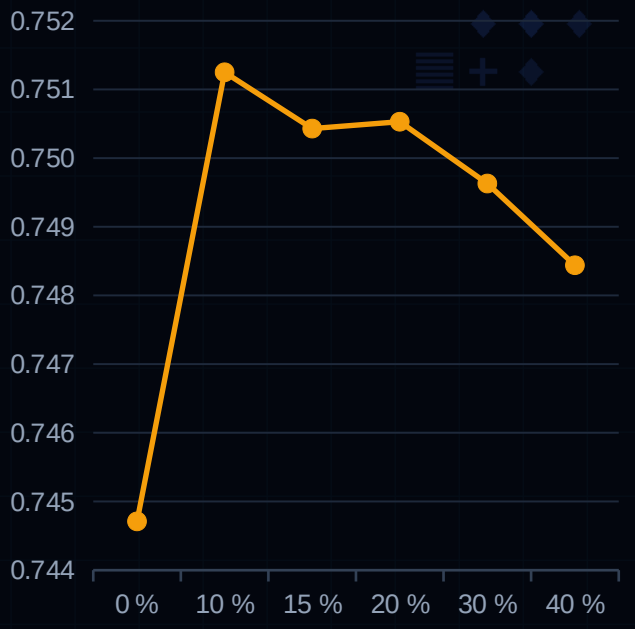
AUC val. 0,7536

Hallazgos de la fase 1 y estudio de ablación

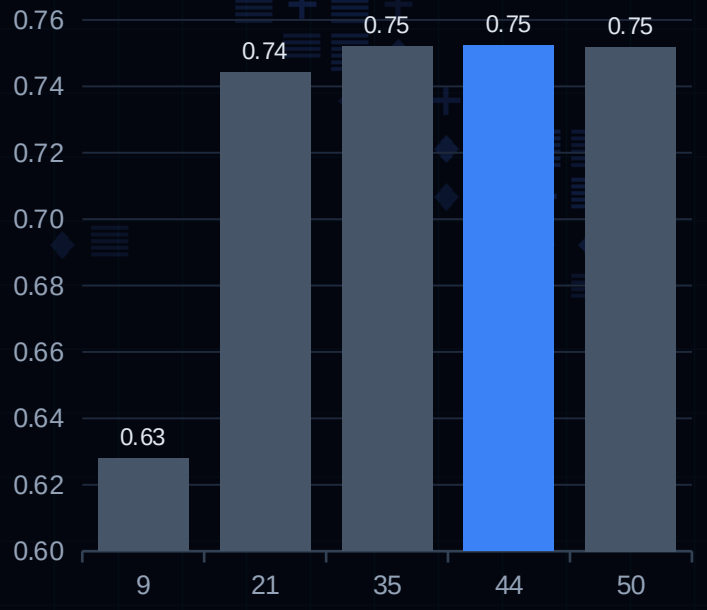
Tamaño de la red (neuronas por capa)



Dropout



Ablación (nº de variables)



Más grande no es mejor

La red más pequeña ([32,16], 1.985 pesos) quedó arriba. Más pesos solo dan más capacidad de memorizar.

Dropout moderado

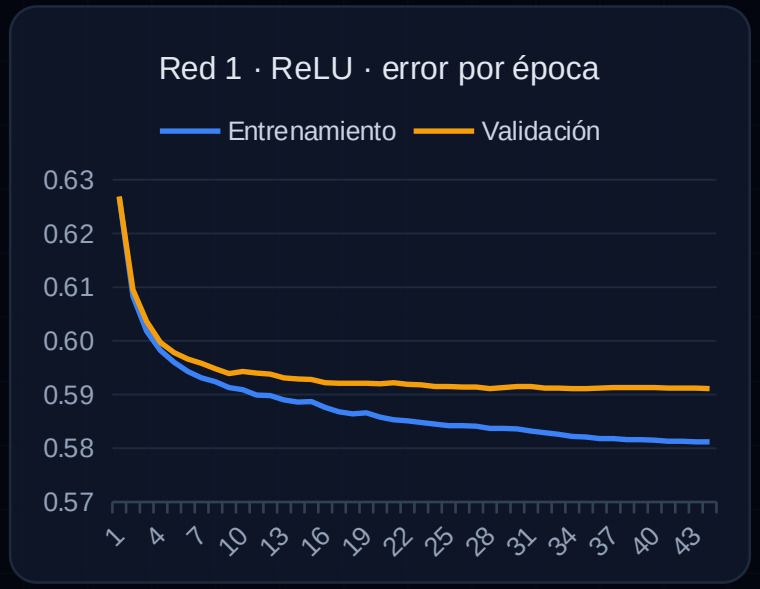
Sin dropout: el peor resultado (0,7447). Con 40 % la red se frena. Lo mejor estuvo entre 10 y 20 %.

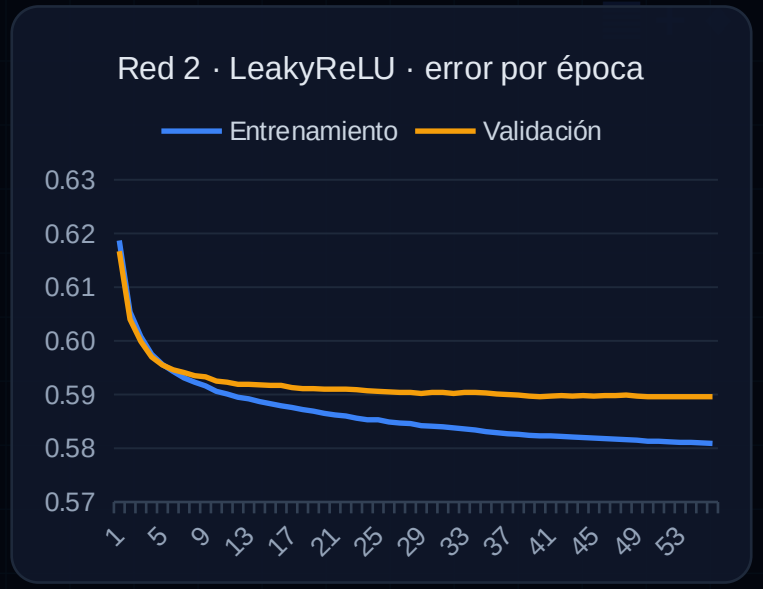
Las 44 variables son necesarias

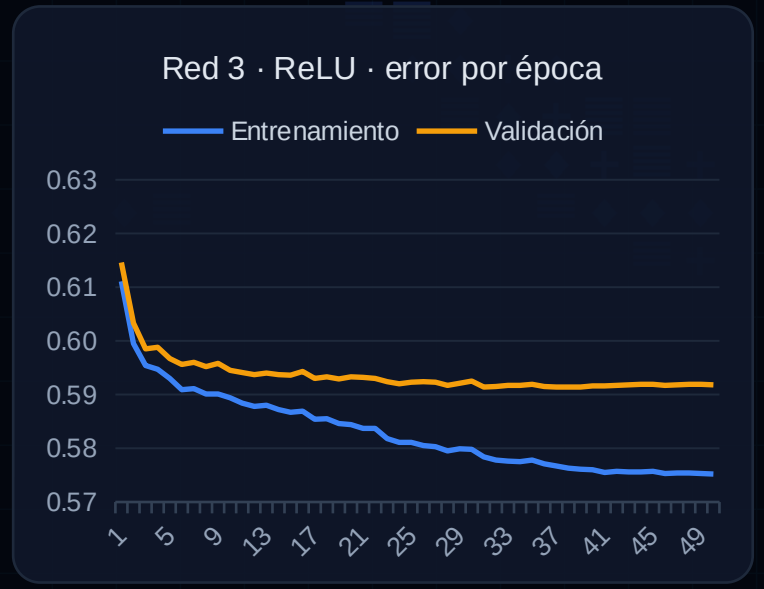
Con 9 variables el AUC cae a 0,628. Agregar 6 indicadores manuales (50) no ayuda.

Prueba 1: curvas de aprendizaje de las tres redes

Azul: error con los clientes de entrenamiento. Naranja: error con los de validación. Si la red memorizara, las curvas se abrirían como una tijera (la azul bajaría y la naranja subiría).







QUÉ HICIMOS

Se reentrenaron las 3 redes con su misma configuración, anotando el error en cada época.

QUÉ BUSCÁBAMOS

Ver si las curvas se separan, que es la señal de memorización.

QUÉ ENCONTRAMOS

Bajan juntas y quedan cerca: la diferencia en la mejor época es de solo 0,008 a 0,015.

Pruebas 2 y 3: sin parada temprana y red que memoriza

PRUEBA 2 · RED 1 ENTRENADA 150 ÉPOCAS SIN FRENO



QUÉ HICIMOS

Dejar la Red 1 entrenando 150 épocas, sin parada temprana.

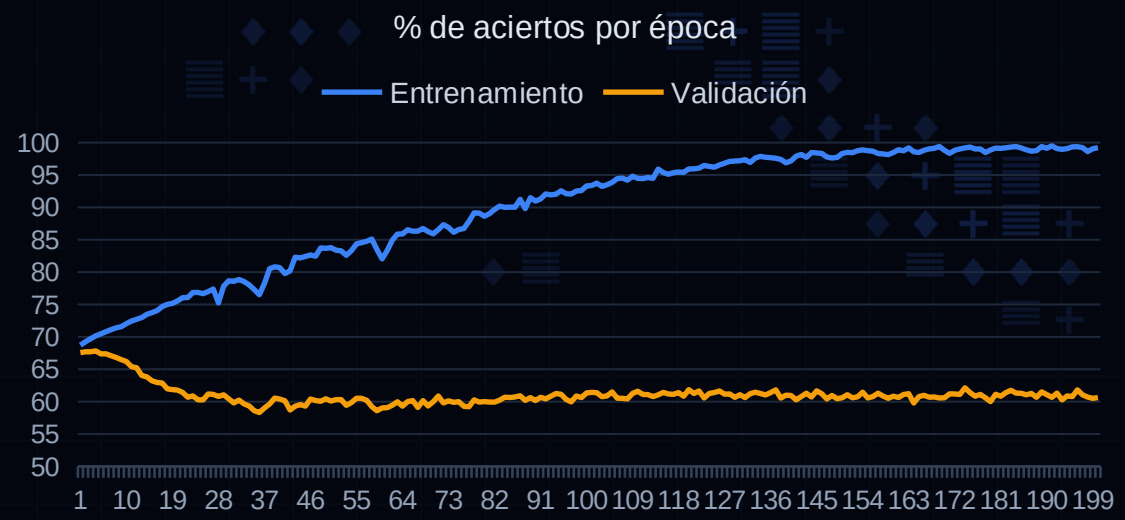
QUÉ BUSCÁBAMOS

Ver si al seguir entrenando la red empieza a memorizar.

QUÉ ENCONTRAMOS

Desde la época 44 (donde el freno la detuvo) la validación empeora; sin freno el AUC baja a 0,738–0,745.

PRUEBA 3 · RED GIGANTE SIN TÉCNICAS (187.393 PESOS)



QUÉ HICIMOS

Entrenar una red 34 veces más grande, sin dropout ni freno, 200 épocas.

QUÉ BUSCÁBAMOS

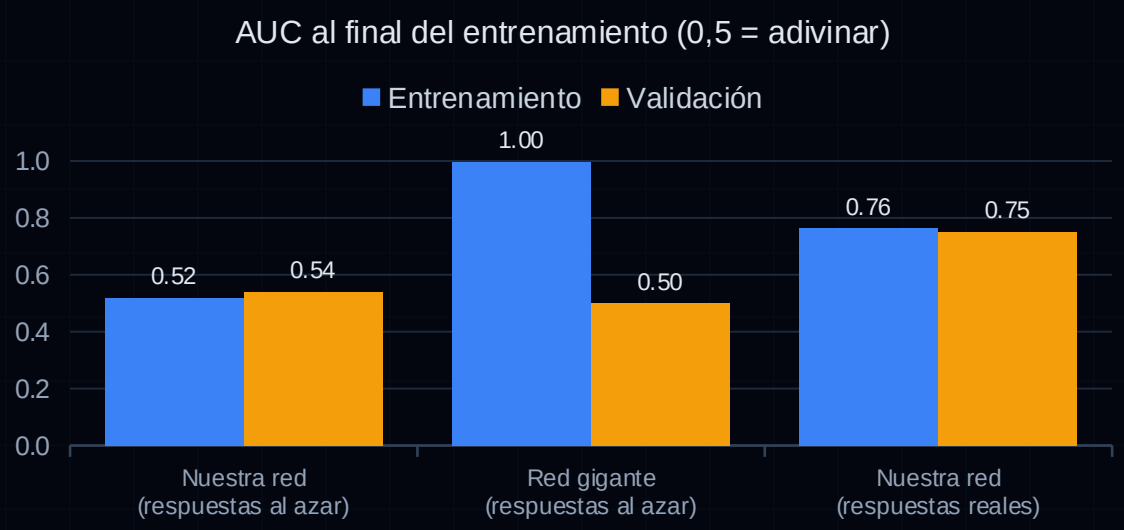
Tener un ejemplo real de memorización para comparar.

QUÉ ENCONTRAMOS

La gigante: 99,2 % vs 60,6 % de aciertos. Nuestra Red 1: 69,8 % vs 68,8 %.

Pruebas 4 y 5: respuestas al azar y cantidad de datos

PRUEBA 4 · RESPUESTAS BARAJADAS AL AZAR



QUÉ HICIMOS

Barajar al azar las respuestas: no queda ningún patrón real.

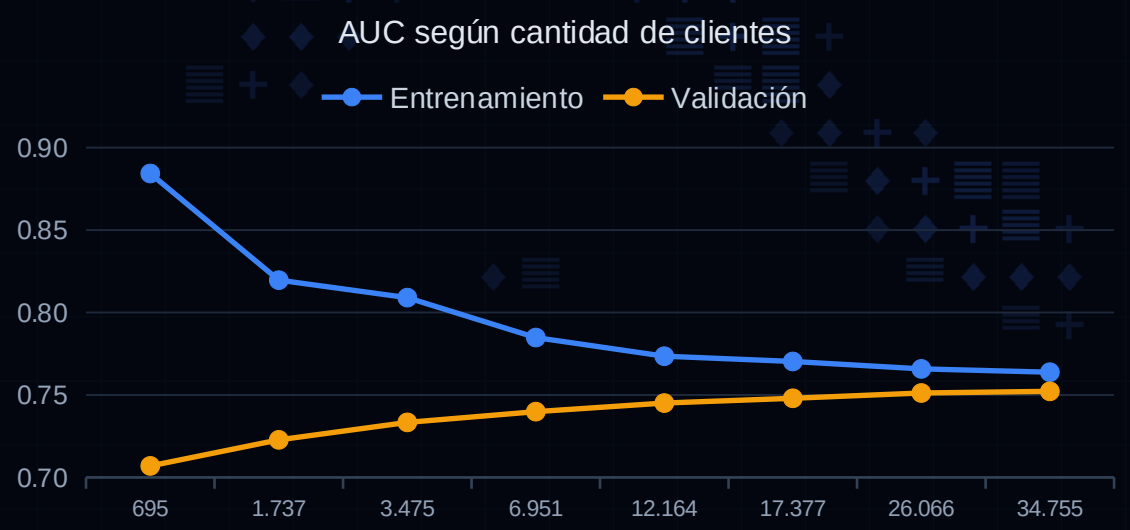
QUÉ BUSCÁBAMOS

Si la red memorizara, se aprendería esas respuestas falsas.

QUÉ ENCONTRAMOS

Nuestra red queda en ≈ 0,5 (adivinar); la gigante llega a 1,0 en entrenamiento. Con respuestas reales, la nuestra llega a 0,75.

PRUEBA 5 · CADA VEZ MÁS CLIENTES PARA ENTRENAR



QUÉ HICIMOS

Entrenar la misma red con el 2 % hasta el 100 % de los clientes.

QUÉ BUSCÁBAMOS

Ver si la brecha entre lo estudiado y lo nuevo se cierra con más datos.

QUÉ ENCONTRAMOS

Con 695 clientes la brecha es 0,177 (memoriza); con 34.755 baja a 0,012.

Resumen de la evidencia: el modelo aprendió

Curvas juntas

Diferencia de error de 0,008 a 0,015 en la mejor época

Parada a tiempo

Se detuvo antes de que las curvas se separaran (épocas 44 a 63)

Distinto a la red gigante

69,8 % vs 68,8 % de aciertos (la gigante: 99 % vs 61 %)

No aprende ruido

Con respuestas al azar se queda en ≈ 0,50

Más datos, menos brecha

La diferencia baja de 0,177 a 0,012

Clientes nunca vistos

AUC de 0,754 en validación a 0,745 en prueba (−1,2 %)

Aclaración: sí existe una diferencia pequeña entre los clientes de entrenamiento (AUC ≈ 0,768) y los nuevos (≈ 0,745). Es normal en cualquier modelo. Memorizar se vería como en la red gigante, con diferencias enormes (99 % frente a 61 %). Por eso concluimos que el modelo aprendió patrones generales.

CrediRisk

Cómo se mide el error (1): en la decisión

Se decide APTO o NO APTO con el umbral de 50 % y se compara con lo que realmente pasó. Valores en el grupo de prueba (7.448 clientes):

Error de clasificación — 32,5 %

`fallos ÷ total`

`2.422 ÷ 7.448`

De cada 100 clientes, se equivoca con 32. Su complemento es la exactitud: 67,5 %.

Precisión — 67,8 %

`aprobados correctos ÷ total de aprobados`

`2.476 ÷ 3.650`

De cada 100 clientes que aprueba, 68 eran realmente buenos pagadores.

Sensibilidad (recall) — 66,5 %

`buenos encontrados ÷ total de buenos`

`2.476 ÷ 3.724`

De cada 100 clientes buenos, el modelo encuentra y aprueba a 66.

F1 — 0,672

`equilibrio entre precisión y sensibilidad`

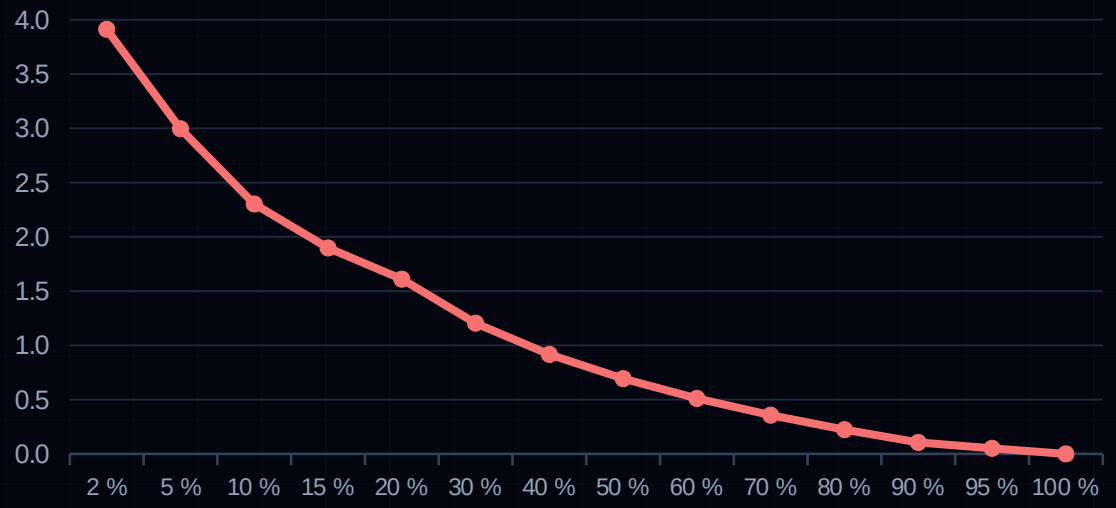
`promedio armónico`

Resume en un solo número qué tan bien acierta con los clientes buenos.

Cómo se mide el error (2): en la probabilidad

Aquí se mide qué tan buena es la probabilidad, antes de decidir. Equivocarse estando «90 % seguro» debe castigarse más que equivocarse estando «55 % seguro».

Castigo según la probabilidad dada a la respuesta correcta



90 % y acierta	castigo 0,11
55 % y acierta	castigo 0,60
10 % (muy seguro y se equivoca)	castigo 2,30

Log loss (entropía cruzada) — **0,596**

Es el error que la red minimiza al entrenar: el promedio de los castigos. Si dijera siempre 50 %, daría 0,693.

Brier — **0,205**

Promedio de (probabilidad − realidad)². Va de 0 (perfecto) a 0,25 (decir siempre 50 %).

AUC — **0,745**

Si se toma un cliente bueno y uno malo al azar, en 3 de cada 4 casos el modelo le da más probabilidad al bueno.

Resultados en el grupo de prueba

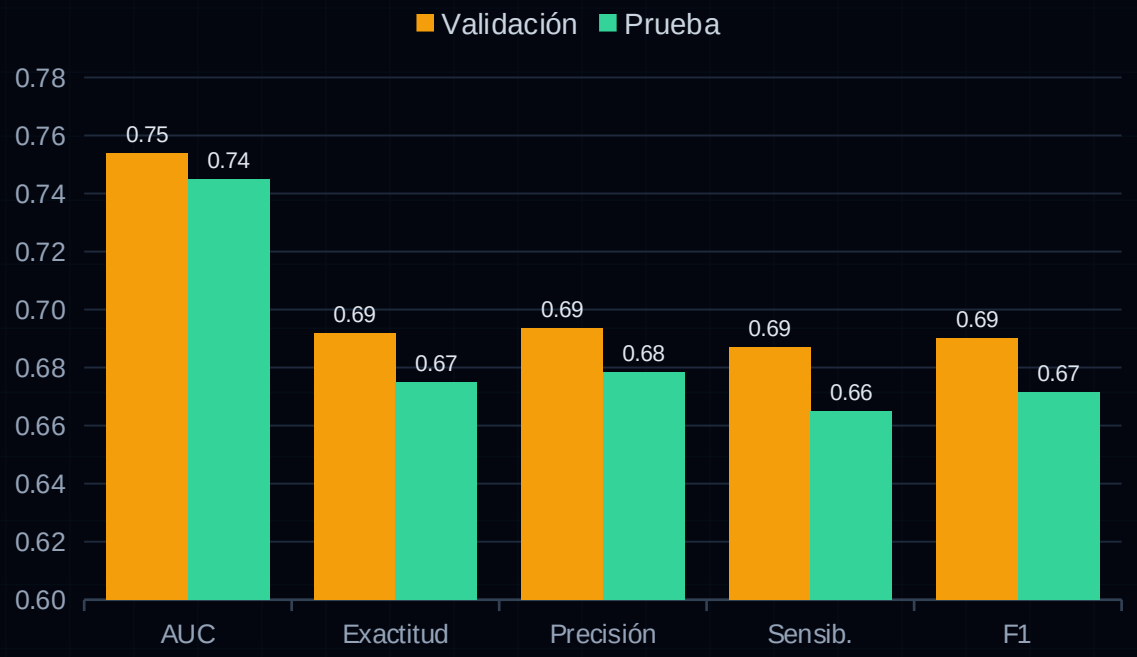
0,745
AUC en prueba: ordena bien 3 de cada 4 parejas bueno / malo

67,5 %
de aciertos (5.026 de 7.448 clientes)

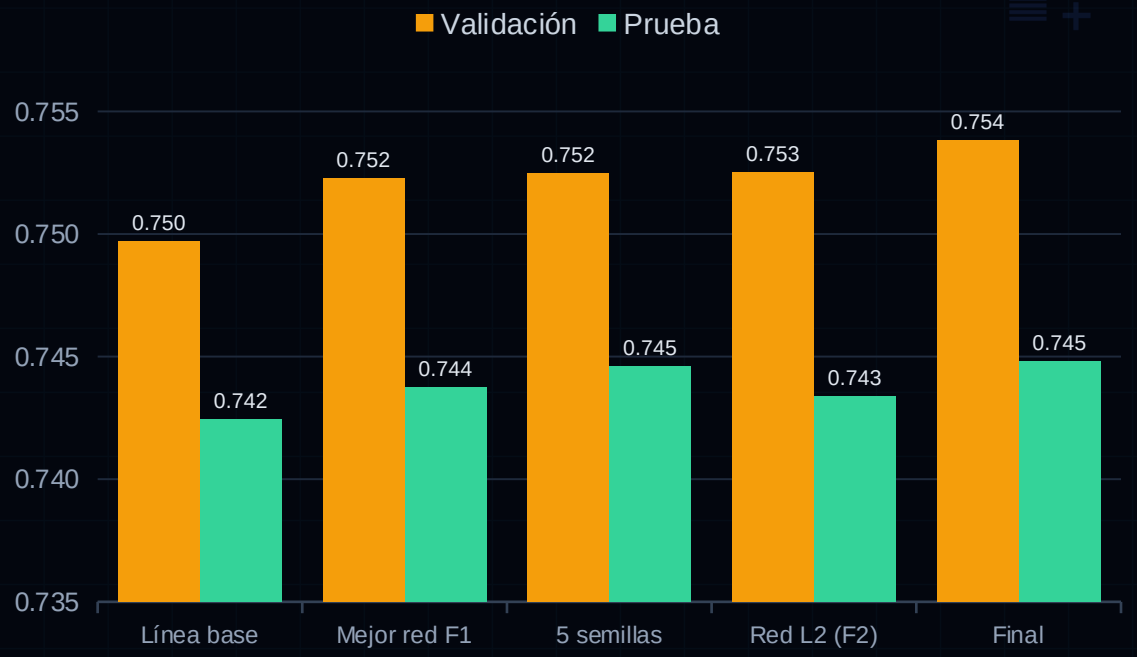
−1,2 %
de caída del AUC frente a validación

+0,0024
de AUC frente a la línea base (mejora modesta)

Validación frente a prueba



Evolución del AUC por etapa

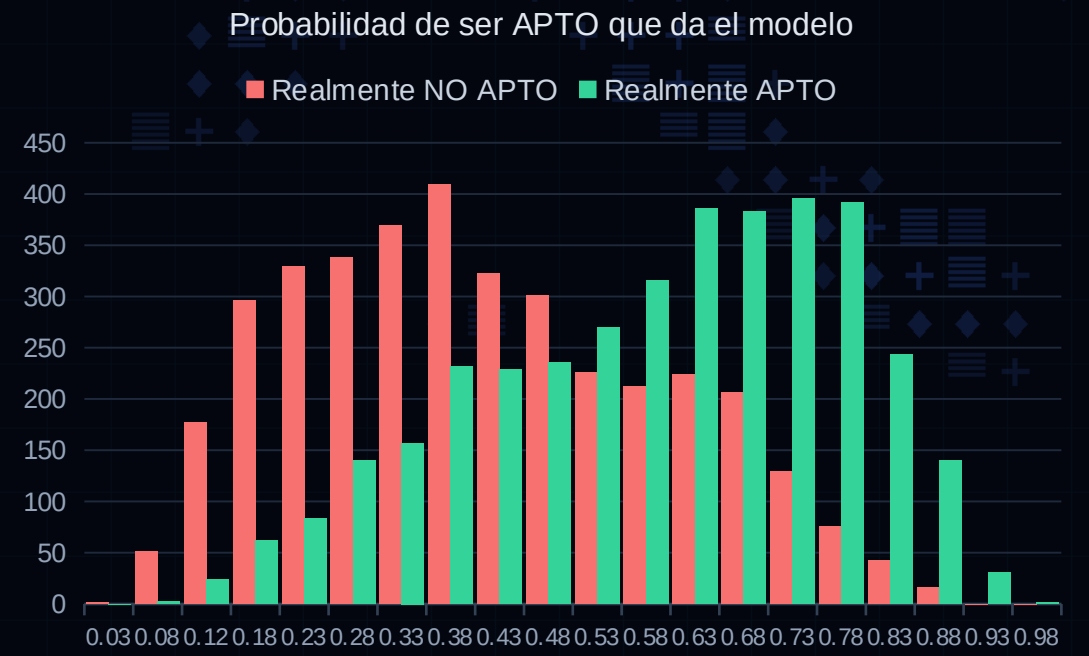


Aciertos, errores y origen del error

	Predicho: NO APTO	Predicho: APTO
Real: NO APTO	**2.550** 34,2 % Riesgosos bien rechazados	**1.174** 15,8 % Riesgosos aprobados por error (el más costoso)
Real: APTO	**1.248** 16,8 % Buenos rechazados por error (negocio perdido)	**2.476** 33,2 % Buenos bien aprobados

Grupo de prueba · 5.026 aciertos y 2.422 errores

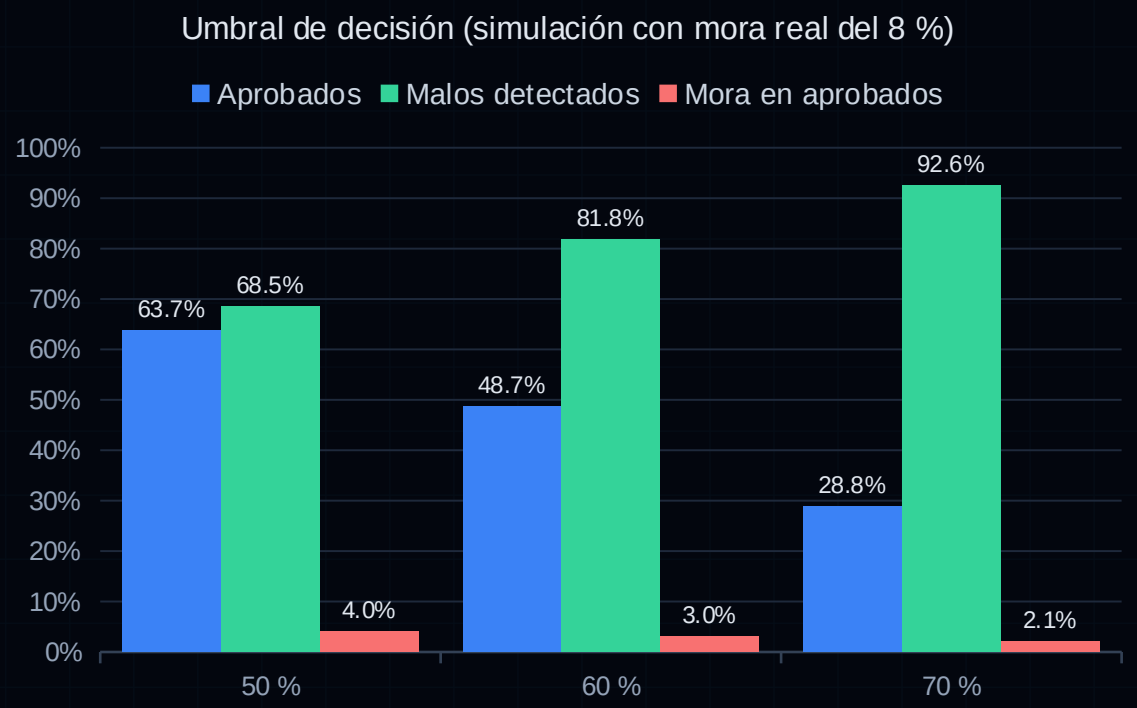
Aprobar a quien no paga le cuesta más al banco que rechazar a un buen cliente.

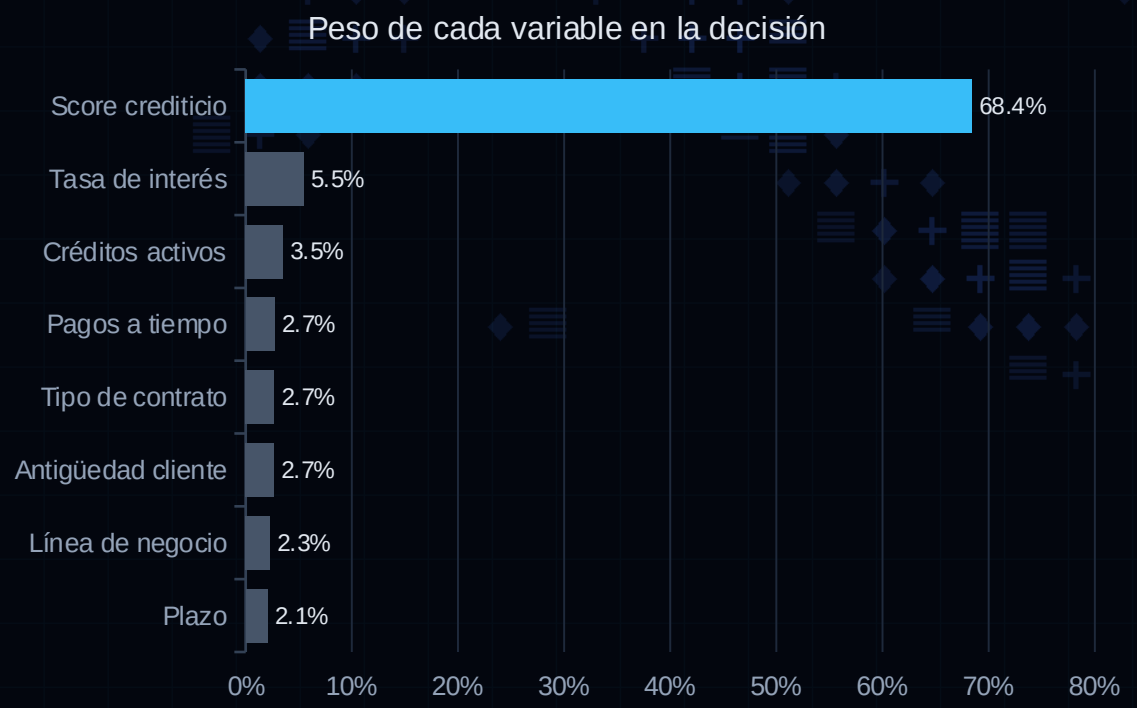


POR QUÉ NO ACIERTA SIEMPRE

Buenos y malos se mezclan en el centro: hay personas con datos casi idénticos y unas pagan y otras no, por causas que no están en los datos (un despido, una enfermedad). Más de 160 redes llegaron al mismo límite (AUC ≈ 0,75).

Umbral de decisión y variables más importantes





Con umbral de 70 % la mora entre aprobados baja de 4,0 % a 2,1 %, pero solo se aprueba al 29 % de los clientes. Elegir el umbral es una decisión del banco, no del modelo.

El score crediticio pesa el 68 %: cómo ha pagado una persona antes es la mejor pista de cómo pagará después. Esto muestra asociación, no causa.

Limitaciones, conclusiones y cierre

LIMITACIONES

- Mejora modesta (+0,0024) sin prueba estadística formal
- Una sola división de los datos (sin validación cruzada)
- Solo se probaron redes MLP
- Umbral de 50 % sin ajustar a costos reales
- Muestra asociación, no causa
- Faltan causas reales del impago en los datos

1

Aprendió, no memorizó

Cinco pruebas lo confirman.

2

Decisiones con evidencia

164 redes, 19 ensambles y 5 semillas.

3

Sin fuga de datos

El grupo de prueba se usó una sola vez.

4

Resultado explicable

Se apoya sobre todo en el historial de pago.

PÁGINA WEB

suntzz.github.io/CrediRisk

Evaluador de crédito, laboratorio del modelo y todas las gráficas.

Gracias · Preguntas