Guion de la presentación CrediRisk

Leidy Guecha · diapositivas 2–8

Diapositiva 2: Contenido de la presentación

La presentación sigue el mismo orden que nuestra página web. Primero los datos: qué queremos predecir y cómo los preparamos. Luego el modelo: cómo funciona una red neuronal y por qué usamos tres.

Después las pruebas que hicimos, la pregunta de si el modelo aprendió o memorizó, los resultados con su error y, al final, las limitaciones y conclusiones.

Diapositiva 3: El problema que resuelve el modelo

Un banco recibe miles de solicitudes de crédito y debe decidir a quién prestarle. Nuestro modelo recibe los datos de cada solicitante y responde con una probabilidad de que sea apto. Si esa probabilidad es de **50 %** o más, lo clasificamos como APTO; si es menor, como NO APTO.

Trabajamos con **49.650** solicitudes, cada una con 23 datos como la edad, los ingresos, las deudas y el historial de pagos. La mitad de los clientes son aptos y la otra mitad no, así que adivinar al azar acertaría el **50 %**.

Diapositiva 4: División de los datos (70 / 15 / 15)

Antes de hacer cualquier cálculo dividimos a los clientes en tres grupos. El **70 %**, unos **34.755** clientes, es el grupo de entrenamiento: como el libro de ejercicios, con él la red aprende. El **15 %** es validación: como los simulacros, sirve para comparar versiones y decidir cuándo parar.

Y el otro **15 %** es el grupo de prueba: el examen final, que guardamos sin tocar y usamos una sola vez. Así la nota final es honesta.

Diapositiva 5: Preparación de los datos

Una red neuronal solo entiende números y funciona mejor si están en escalas parecidas. Por eso hicimos cuatro pasos. Primero limpiamos: quitamos el número de solicitud y una columna que era la respuesta disfrazada; dejarla sería hacer trampa.

Segundo, si falta un dato lo rellenamos con el valor típico y agregamos un aviso de que faltaba. Tercero, suavizamos valores extremos, como ingresos muy altos. Y cuarto, convertimos las categorías en columnas de ceros y unos y llevamos todo a la misma escala; todo esto se calculó solo con el grupo de entrenamiento.

Diapositiva 6: De 23 datos a 44 variables de entrada

Por eso pasamos de 23 datos a 44 números, sin agregar información nueva. Las 19 variables numéricas siguen siendo 19 columnas, y se agregan 7 columnas de aviso de dato faltante.

Las 4 variables de categorías se convierten en 18 columnas. Por ejemplo, una persona casada se escribe como 0, 1, 0, 0, 0. No usamos números como 1, 2 o 3, porque la red creería que una categoría es mayor que otra.

Diapositiva 7: Cómo aprende una red neuronal

Una red neuronal es un conjunto de pequeñas calculadoras, llamadas neuronas, organizadas en capas. Cada conexión tiene un número llamado peso, y aprender significa ajustar esos pesos.

El ciclo tiene cuatro pasos: la red toma 128 clientes y predice una probabilidad para cada uno; mide el error comparando con la respuesta real; calcula cuánto contribuyó cada peso a ese error; y el optimizador Adam corrige cada peso un poquito. Esto se repite **272** veces por cada vuelta completa a los datos, que llamamos época.

Diapositiva 8: Partes de una neurona: pesos, sesgo y función de activación

Veamos una neurona de cerca. Recibe los 44 datos del cliente y multiplica cada uno por su peso, que indica qué tan importante es ese dato. Luego suma todo y le agrega el sesgo, un número propio de cada neurona que le permite activarse aunque las entradas sean cero, como el punto de partida de una recta.

Por último aplica la función de activación, que decide cuánto se enciende. En el ejemplo de abajo, con dos entradas, el total da **0,14** y ReLU entrega **0,14**. Ahora Sharick les explicará las funciones de activación.

Sharick Hernández · diapositivas 9–15

Diapositiva 9: Funciones de activación utilizadas

Gracias, Leidy. Estas son las funciones de activación que usamos y por qué. ReLU, en las capas ocultas de las Redes 1 y 3, deja pasar los valores positivos y convierte los negativos en cero: es simple y rápida de entrenar.

LeakyReLU, en la Red 2, deja pasar un **10 %** de los negativos, para que ninguna neurona se apague del todo. La sigmoide, en la salida de las tres redes, convierte el resultado en una probabilidad entre 0 y 1. ELU y GELU las probamos en la fase 3, pero no superaron al modelo final.

Diapositiva 10: Arquitectura completa de la Red 1

Esta es la Red 1 completa. Entran los 44 números del cliente. La primera capa oculta tiene 64 neuronas, cada una con 44 pesos y un sesgo, es decir **2.816** pesos y 64 sesgos, y usa ReLU con **15 %** de dropout.

La segunda tiene 32 neuronas y la tercera 16. La salida es una sola neurona con sigmoide, que entrega la probabilidad. En total son **5.392** pesos y 113 sesgos: **5.505** parámetros; después de entrenar, por ejemplo, el sesgo de salida quedó en menos **0,063**.

Diapositiva 11: Arquitectura de las Redes 2 y 3

Las otras dos redes siguen la misma lógica, pero cambian. La Red 2 es más pequeña: dos capas ocultas de 32 y 16 neuronas con LeakyReLU, y dropout solo en la primera; tiene **1.985** parámetros. La Red 3 tiene la misma forma que la Red 1, pero con **20 %** de dropout, un paso de aprendizaje mayor y otra semilla, así que sus pesos y sesgos aprendidos son distintos.

Diapositiva 12: Técnicas para evitar la memorización

Con miles de pesos, una red puede terminar aprendiéndose de memoria los clientes de entrenamiento. Usamos cuatro técnicas. El dropout apaga al azar el **15 %** o el **20 %** de las neuronas en cada paso, como estudiar en grupo cuando cada día faltan compañeros distintos.

La parada temprana detiene el entrenamiento si pasan 12 épocas sin mejorar en validación. Si se estanca 5 épocas, reducimos a la mitad el tamaño de cada corrección. Y mantuvimos las redes compactas, con poca memoria disponible.

Diapositiva 13: Ensamble de tres redes neuronales

El modelo final no es una sola red. Son tres redes diferentes que evalúan al mismo cliente por separado. Cada una entrega su probabilidad, p1, p2 y p3, y luego las promediamos.

Si el promedio es de **50 %** o más, el cliente es APTO. Funciona como un comité de tres evaluadores, donde cada uno tiene el mismo voto.

Diapositiva 14: Diferencias entre las tres redes

Las tres redes se eligieron a propósito para que fueran diferentes, porque si fueran iguales cometerían los mismos errores. Cambian en el número de neuronas, la función de activación, el dropout, el tamaño del paso de aprendizaje y la semilla. Cada una, sola, logra un AUC cercano a **0,752**.

La Red 1 es la base, la Red 2 aporta otra forma de pensar y la Red 3 otro punto de partida.

Diapositiva 15: Cómo vota el ensamble

Veamos cómo vota. Al cliente A, las redes le dan **0,62**, **0,48** y **0,57**: el promedio es **0,557** y es APTO. La Red 2 sola lo habría rechazado, pero las otras dos la corrigen.

Comprobamos que lo que ayuda es la diversidad: una sola red llega a **0,7523**; cinco copias de la misma red, a **0,7525**; y tres redes distintas, a **0,7538**, el mejor resultado. Laura nos contará cómo llegamos a este modelo.

Laura Díaz · diapositivas 16–24

Diapositiva 16: Experimentos realizados

Gracias, Sharick. Ahora vamos a contar cómo llegamos a este modelo. Ninguna decisión se tomó con una sola prueba: siempre comparamos varias, usando el grupo de validación.

Diapositiva 17: Cantidad de pruebas realizadas

En total entrenamos **164** redes neuronales y evaluamos 19 combinaciones. Además, cada configuración importante la repetimos con 5 semillas distintas, es decir, barajando el azar de otra forma, para comprobar que el resultado no era suerte. El grupo de prueba se usó una sola vez, al final.

Diapositiva 18: Qué se buscó en cada etapa

El trabajo se hizo por etapas y cada una partió de lo mejor de la anterior. La línea base nos dio un punto de partida, con un AUC de **0,7497**. En la fase 1, con 37 pruebas, exploramos el tamaño de la red, el paso de aprendizaje y el dropout.

En la fase 2, con 29 pruebas, afinamos y probamos combinar redes; ahí ganó el ensamble de tres redes, con **0,7538**. Y en la fase 3, con 12 pruebas, probamos técnicas más modernas, que empataron pero no lo superaron.

Diapositiva 19: Resultados de la exploración inicial (fase 1)

En la fase 1 cambiamos un solo factor a la vez. Dos resultados importantes: las redes más grandes no mejoraron, e incluso la más pequeña quedó arriba; más pesos solo dan más capacidad de memorizar.

Y el dropout: sin él obtuvimos el peor resultado, **0,7447**, y con **40 %** la red se frena demasiado. También vimos que el paso de aprendizaje ideal era **0,0005**.

Diapositiva 20: Efecto de quitar o agregar variables (ablación)

El estudio de ablación entrena la misma red con distintos grupos de variables. Con solo 9 variables financieras, el AUC cae a **0,628**. Con 21 sube a **0,744** y con las 44 llega al máximo, **0,752**.

Agregar 6 indicadores calculados a mano no ayuda, porque la red ya aprende esas relaciones sola. Por eso usamos las 44.

Diapositiva 21: Número de épocas de entrenamiento

Una época es una vuelta completa a los **34.755** clientes, con 272 correcciones de pesos. No fijamos un número de épocas: pusimos un máximo de 100 y dejamos que la parada temprana decidiera. En promedio los entrenamientos duraron 41 épocas.

Las tres redes finales tuvieron su mejor punto en las épocas 32, 51 y 36; después esperaron 12 épocas sin mejorar, se detuvieron y recuperaron su mejor versión.

Diapositiva 22: Aprendizaje o memorización

Llegamos a la pregunta central: ¿el modelo aprendió reglas que sirven para clientes nuevos, o solo memorizó los ejemplos? Lo comprobamos con cinco pruebas.

Diapositiva 23: Cómo leer una curva de aprendizaje

Primero, cómo leer una curva de aprendizaje. La línea azul es el error con los clientes de entrenamiento y la naranja, con los de validación. A la izquierda, un modelo que aprende: las dos curvas bajan juntas y quedan cerca.

A la derecha, uno que memoriza: el error de entrenamiento baja casi a cero, pero el de validación sube. Las curvas se abren como una tijera.

Diapositiva 24: Prueba 1: curvas de las tres redes del modelo final

Estas son las curvas reales de nuestras tres redes. Las volvimos a entrenar con su misma configuración y anotamos el error en cada época. Si memorizaran, las curvas se abrirían; pero bajan juntas y se mantienen cerca.

En la mejor época, la diferencia de error es de solo **0,008** a **0,015**. Iván continúa con las demás pruebas.

Iván Solano · diapositivas 25–32

Diapositiva 25: Prueba 2: entrenamiento sin parada temprana

Gracias, Laura. En la prueba 2 quitamos el freno: dejamos la Red 1 entrenando **150** épocas sin parada temprana. Queríamos ver si al seguir entrenando empezaba a memorizar.

Y sí: después de la época 44, justo donde el freno la había detenido, la validación empeora mientras el entrenamiento sigue mejorando. Sin freno, el AUC baja a entre **0,738** y **0,745**; con freno es de **0,752**.

Diapositiva 26: Prueba 3: comparación con una red que memoriza

En la prueba 3 entrenamos a propósito una red gigante, de **187.393** pesos, 34 veces más grande que la nuestra, sin dropout y sin freno, durante 200 épocas. Queríamos un ejemplo real de memorización.

La gigante llega a **99,2 %** de aciertos en entrenamiento, pero solo **60,6 %** en validación. Nuestra Red 1 tiene **69,8 %** y **68,8 %**, casi iguales.

Diapositiva 27: Prueba 4: entrenamiento con respuestas al azar

La prueba 4 es la más contundente. Barajamos al azar las respuestas de los clientes, de modo que no quedaba ningún patrón real. Una red que memoriza se aprendería esas respuestas falsas.

Nuestra red se quedó en **0,50** a **0,54**, igual que adivinar, y se detuvo sola. La gigante, en cambio, llegó a **1,0** en entrenamiento: memorizó ruido. Con las respuestas reales, la nuestra llega a **0,754**: aprende patrones reales.

Diapositiva 28: Prueba 5: curva de aprendizaje según la cantidad de datos

En la prueba 5 entrenamos la misma red con cada vez más clientes, desde el **2 %** hasta el **100 %**. Queríamos ver si la diferencia entre lo estudiado y lo nuevo se cerraba con más datos.

Con solo **695** clientes la diferencia es de **0,177**: la red memoriza. Con los **34.755** baja a **0,012**, y el AUC en clientes nuevos sube de **0,707** a **0,752**.

Diapositiva 29: Resumen de la evidencia

En resumen, todas las pruebas apuntan a lo mismo: las curvas van juntas, la parada temprana actuó a tiempo, el modelo no se parece a la red gigante, no aprende ruido y la diferencia se cierra con más datos. Además, con clientes nunca vistos el AUC solo bajó de **0,754** a **0,745**.

Sí hay una diferencia pequeña entre entrenamiento y prueba, pero es normal. Por eso concluimos que el modelo aprendió.

Diapositiva 30: Resultados y medición del error

Pasamos a los resultados. Primero explicamos cómo se mide el error y luego mostramos los números del examen final, con **7.448** clientes que el modelo nunca vio.

Diapositiva 31: Cómo se mide el error (1): error en la decisión

La primera forma de medir el error es contar. Decidimos APTO o NO APTO con el umbral de **50 %** y comparamos con lo que realmente pasó. El error de clasificación es fallos entre total: **2.422** entre **7.448**, es decir **32,5 %**.

La precisión dice que de cada 100 clientes que aprueba, 68 eran buenos pagadores. La sensibilidad, que de cada 100 clientes buenos encuentra a 66. Y el F1, de **0,672**, resume el equilibrio entre ambas.

Diapositiva 32: Cómo se mide el error (2): error en la probabilidad

La segunda forma mide qué tan buena es la probabilidad, antes de decidir. El log loss es el error que la red minimiza al entrenar: castiga poco una respuesta segura y correcta, y muchísimo una muy segura pero equivocada, como muestra la gráfica. Si dijera siempre **50 %**, daría **0,693**; el nuestro es **0,596**.

El Brier va de 0, perfecto, a **0,25**; el nuestro es **0,205**. Y el AUC de **0,745** significa que, tomando un cliente bueno y uno malo al azar, en 3 de cada 4 casos el modelo le da más probabilidad al bueno. Cristian les mostrará los resultados.

Cristian Martínez · diapositivas 33–40

Diapositiva 33: Resultados en el grupo de prueba

Gracias, Iván. Estos son los resultados del examen final. El AUC es **0,745** y el modelo acierta el **67,5 %** de los clientes, es decir, **5.026** de **7.448**.

Frente a validación, el AUC solo cae **1,2 %**, lo que indica que el modelo generaliza. Todas las métricas se mantienen cerca entre validación y prueba.

Diapositiva 34: Evolución del AUC por etapa

Así cambió el AUC desde la línea base hasta el modelo final, en validación y en prueba. La mejora en prueba es de **0,0024**: es modesta y lo decimos con honestidad. El aporte principal del proyecto es el método: sin fuga de datos, con pruebas para cada decisión y reproducible.

Diapositiva 35: Aciertos y errores en el grupo de prueba

Esta es la matriz de confusión. En verde, los aciertos: **2.550** clientes riesgosos bien rechazados y **2.476** buenos bien aprobados.

En rojo, los errores: **1.174** riesgosos que el modelo aprobaría, que es el error más costoso para un banco, y **1.248** buenos que rechazaría, que es negocio perdido. Los errores se reparten casi por igual.

Diapositiva 36: Por qué el modelo no acierta siempre

¿Por qué no acierta siempre? La gráfica muestra las probabilidades que el modelo da a los clientes buenos y a los malos: se mezclan en el centro. Hay muchas personas con datos casi idénticos y unas pagan y otras no, por causas que no están en la base de datos, como un despido o una enfermedad.

Ningún modelo puede separar lo que los datos no distinguen; más de 160 redes llegaron al mismo límite.

Diapositiva 37: Efecto del umbral de decisión

El umbral de **50 %** es neutral, pero un banco puede ser más exigente. En esta simulación con la mora real del mercado, si el umbral sube a **70 %**, la mora entre los aprobados baja de **4 %** a **2,1 %**, pero solo se aprueba al **29 %** de los clientes. Elegir el umbral es una decisión del banco, no del modelo.

Diapositiva 38: Variables con más peso en la decisión

Para saber en qué se fija el modelo, revolvimos cada variable y medimos cuánto empeoraba. El score crediticio concentra el **68 %** del peso: la forma en que una persona ha pagado antes es la mejor pista de cómo pagará después. Le siguen la tasa de interés y el número de créditos activos; ojo, esto muestra asociación, no causa.

Diapositiva 39: Limitaciones del estudio

Queremos ser transparentes con los límites. La mejora frente a la línea base es modesta y no hicimos una prueba estadística formal. Usamos una sola división de los datos y solo probamos redes de este tipo.

El umbral de **50 %** no refleja que un impago le cuesta más al banco que rechazar a un buen cliente. Y el modelo muestra asociaciones, no causas, porque faltan datos como despidos o problemas de salud.

Diapositiva 40: Conclusiones

Para cerrar: el modelo final es un ensamble de tres redes que alcanza un AUC de **0,745** en clientes nunca vistos. Concluimos cuatro cosas: aprendió y no memorizó; cada decisión se tomó con evidencia, entrenando **164** redes; no hubo fuga de datos; y el resultado es explicable, porque se apoya sobre todo en el historial de pago.

Los invitamos a escanear el código para probar el evaluador en nuestra página.

Diapositiva 41: Cierre (todos)

Muchas gracias por su atención. Quedamos atentos a sus preguntas y comentarios.