Guion CrediRisk (20 diapositivas)

Oct 26, 2026 · @ivan solano

Guion para la versión de 20 diapositivas, de unos 18 minutos. Los cinco hablan en la portada y al final; las diapositivas 2 a 20 se reparten en 4 por persona, con unos 3,5 minutos de habla cada uno.

Reparto de diapositivas

Integrante	Diapositivas	Tema	Tiempo aprox.
Todos	1	Presentación: cada uno dice su nombre; Cristian, Iván y Laura presentan el proyecto	1 min
Leidy Guecha	2–4	Problema y datos, preparación (23 → 44 variables), cómo funciona una neurona	3,5 min
Sharick Hernández	5–8	Arquitectura de las 3 redes, funciones de activación, técnicas y épocas, ensamble	3,5 min
Laura Díaz	9–12	Pruebas por etapa, fase 1 y ablación, pruebas 1 a 3 de memorización	3,5 min
Iván Solano	13–16	Pruebas 4 y 5, resumen de la evidencia, cómo se mide el error	3,5 min
Cristian Martínez	17–20	Resultados, matriz de confusión, umbral y variables, limitaciones y conclusiones	3,5 min
Todos	20 (final)	Agradecimiento y preguntas	—

Cada parte termina pasando la palabra a quien sigue. No hace falta leerlo palabra por palabra: lo importante son los números en negrita y la idea de cada diapositiva. El mismo texto está en las notas del orador del PowerPoint.

Diapositiva 1: Portada y equipo (todos)

Leidy: Buenos días, profesora y compañeros. Somos el equipo CrediRisk y cada uno se va a presentar. Yo soy Leidy Guecha.

Sharick: Yo soy Sharick Hernández. **Laura:** Yo soy Laura Díaz. **Iván:** Yo soy Iván Solano. **Cristian:** Y yo soy Cristian Martínez.

Cristian: Nuestro proyecto es un sistema que ayuda a decidir si una persona es apta o no para recibir un crédito de consumo. Para eso usamos un ensamble, es decir, un grupo de tres redes neuronales que trabajan juntas.

Iván: Con clientes que el modelo nunca había visto obtuvimos un AUC de **0,745**; más adelante explicamos qué significa ese número.

Laura: Todo lo que vamos a mostrar también está en nuestra página web, que pueden visitar al final con el código QR. Leidy empieza con el problema.

Leidy Guecha · diapositivas 2–4

Diapositiva 2: El problema y los datos

Empecemos por el problema. Un banco recibe miles de solicitudes de crédito y tiene que decidir a quién prestarle. Nuestro modelo recibe los datos de cada solicitante y responde con una probabilidad de que la persona sea apta.

Si esa probabilidad es de **50 %** o más, la clasificamos como APTO; si es menor, como NO APTO. Trabajamos con **49.650** solicitudes reales, cada una con 23 datos, como la edad, los ingresos, las deudas y el historial de pagos. La mitad de los clientes son aptos y la otra mitad no, así que adivinar al azar acertaría el **50 %**.

Antes de hacer cualquier cálculo dividimos a los clientes en tres grupos. El **70 %** es el grupo de entrenamiento: como el libro de ejercicios, con él la red aprende. El **15 %** es validación: como los simulacros, sirve para comparar versiones y elegir la mejor.

Y el otro **15 %** es el grupo de prueba: el examen final, que guardamos sin tocar y usamos una sola vez al final. Así la nota final es honesta.

Diapositiva 3: Preparación de los datos: de 23 a 44 variables

Una red neuronal solo entiende números, y funciona mejor si están en escalas parecidas. Por eso los datos pasan por cuatro pasos. Primero limpiamos: quitamos el número de solicitud, que no dice nada de la persona, y una columna que era la respuesta disfrazada;

dejarla sería hacer trampa.

Segundo, si falta un dato lo rellenamos con el valor típico y agregamos un aviso de que faltaba. Tercero, suavizamos los valores extremos, como ingresos muy altos. Y cuarto, convertimos las categorías en columnas de ceros y unos y llevamos todo a la misma escala.

Por eso pasamos de 23 datos a 44 números: las 19 variables numéricas siguen siendo 19 columnas; se agregan 7 columnas de aviso de dato faltante; y las 4 variables de categorías se convierten en 18 columnas. Por ejemplo, una persona casada se escribe como 0, 1, 0, 0, 0. No usamos números como 1, 2 o 3 porque la red creería que una categoría es mayor que otra.

Algo importante: todos estos cálculos se hicieron solo con el grupo de entrenamiento.

Diapositiva 4: Cómo funciona y cómo aprende una neurona

Una red neuronal está formada por neuronas, y todas funcionan igual. Cada neurona recibe los 44 números del cliente y multiplica cada uno por un peso; el peso indica qué tan importante es ese dato para esa neurona. Luego suma todo y le agrega el sesgo, que es un número propio de cada neurona; le permite activarse aunque las entradas sean cero, como el punto de partida de una recta.

Por último aplica la función de activación, que decide cuánto se enciende la neurona. Abajo ven cómo aprende la red: toma **128** clientes, calcula una probabilidad para cada uno, compara con la respuesta real para medir el error, calcula cuánto contribuyó cada peso a ese error y corrige un poquito cada peso. Ese ciclo se repite **272** veces por cada vuelta completa a los datos, y a cada vuelta la llamamos época.

Ahora Sharick les mostrará cómo se arma la red completa.

Sharick Hernández · diapositivas 5–8

Diapositiva 5: Arquitectura de las tres redes

Gracias, Leidy. Esta es la red completa. La Red 1, la principal, recibe los 44 números y los pasa por tres capas ocultas de 64, 32 y 16 neuronas, que usan la función ReLU.

Cada capa tiene sus pesos y un sesgo por neurona: por ejemplo, la primera capa tiene 44 por 64, es decir **2.816** pesos, y 64 sesgos. Al final hay una sola neurona de salida con función sigmoide, que entrega la probabilidad de ser apto. En total la Red 1 tiene **5.505**

parámetros, y después de entrenar, por ejemplo, el sesgo de la salida quedó en menos **0,063**.

Las otras dos redes siguen la misma lógica: la Red 2 es más pequeña, con capas de 32 y 16 neuronas y la función LeakyReLU, y la Red 3 tiene la misma forma que la Red 1, pero con más dropout y otra semilla.

Diapositiva 6: Funciones de activación

Ahora, ¿qué funciones de activación usamos y por qué? En las capas ocultas de las Redes 1 y 3 usamos ReLU: deja pasar los valores positivos y convierte los negativos en cero. Es simple y rápida de entrenar.

En la Red 2 usamos LeakyReLU, que es parecida, pero deja pasar un **10 %** de los valores negativos; así ninguna neurona se apaga del todo, y además hace que esa red piense distinto a las otras dos. En la salida de las tres redes usamos sigmoide, que convierte el resultado en una probabilidad entre 0 y 1.

En la fase 3 también probamos ELU y GELU, que son versiones suaves de ReLU. ELU fue muy estable, pero ninguna superó al modelo final.

Diapositiva 7: Técnicas contra la memorización y épocas

Una red con miles de pesos puede terminar aprendiéndose de memoria los clientes de entrenamiento. Para evitarlo usamos cuatro técnicas. El dropout apaga al azar el **15 %** o el **20 %** de las neuronas en cada paso, para que la red no dependa de unas pocas.

La parada temprana detiene el entrenamiento si pasan 12 épocas sin mejorar en validación, y recupera la mejor versión. Si la red se estanca 5 épocas, reducimos a la mitad el tamaño de cada corrección. Y mantuvimos redes compactas.

Sobre las épocas: no fijamos un número; pusimos un máximo de **100** y dejamos que la parada temprana decidiera. Las tres redes finales tuvieron su mejor punto en las épocas 32, 51 y 36, y se detuvieron 12 épocas después.

Diapositiva 8: Ensamble de tres redes

El modelo final no es una sola red: son las tres redes que acabamos de ver. Cada una evalúa al mismo cliente por separado, luego promediamos las tres probabilidades y con ese promedio decidimos. Es como un comité de tres evaluadores.

Por ejemplo, si un cliente recibe **0,62**, **0,48** y **0,57**, el promedio es **0,557** y es APTO: la Red 2 sola lo habría rechazado, pero el comité la corrige. ¿Por qué tres redes distintas y no tres iguales? Lo comprobamos: una sola red llegó a un AUC de **0,7523**; cinco copias de la misma red, a **0,7525**; y tres redes diferentes, a **0,7538**, que fue el mejor resultado.

Lo que ayuda es la diversidad, porque cada red se equivoca en clientes un poco distintos. Ahora Laura les contará cómo llegamos a este modelo.

Laura Díaz · diapositivas 9–12

Diapositiva 9: Pruebas realizadas por etapa

Gracias, Sharick. No nos quedamos con la primera red que funcionó. En total entrenamos **164** redes y evaluamos 19 combinaciones, y cada configuración importante la repetimos con 5 semillas distintas para comprobar que el resultado no era suerte.

El trabajo se hizo por etapas. La línea base nos dio un punto de partida, con un AUC de **0,7497**. En la fase 1, con 37 pruebas, exploramos el tamaño de la red, el paso de aprendizaje y el dropout.

En la fase 2, con 29 pruebas, afinamos esos valores y probamos combinar redes; ahí apareció el ensamble de 3 redes, el mejor con **0,7538**. Y en la fase 3, con 12 pruebas, probamos técnicas más modernas, que empataron pero no superaron al ensamble. Cada fase partió de lo mejor de la anterior.

Diapositiva 10: Fase 1 y estudio de ablación

Algunos resultados importantes de las pruebas. A la izquierda, las redes más grandes no funcionaron mejor; incluso la más pequeña quedó arriba. Más pesos solo dan más capacidad de memorizar.

En el centro, el dropout: sin dropout obtuvimos el peor resultado, y con **40 %** la red se frena demasiado; el punto adecuado estuvo entre **10 %** y **20 %**. A la derecha está el estudio de ablación, donde entrenamos la misma red con distintos grupos de variables. Con solo 9 variables financieras el AUC cae a **0,628**.

Con las 44 llega al máximo. Y agregar 6 indicadores calculados a mano no ayuda, porque la red ya aprende esas relaciones sola.

Diapositiva 11: Prueba 1: curvas de las tres redes

La pregunta más importante es si el modelo aprendió reglas generales o solo memorizó los ejemplos. Para responderla miramos las curvas de aprendizaje: la línea azul es el error con los clientes de entrenamiento y la naranja, con los de validación. Si la red memorizara, la azul seguiría bajando y la naranja subiría: se abrirían como una tijera.

Lo que vemos en nuestras tres redes es que ambas curvas bajan juntas y se quedan cerca. En el mejor punto la diferencia de error es de apenas **0,008** a **0,015**.

Diapositiva 12: Pruebas 2 y 3: sin parada temprana y red gigante

En la prueba 2 quitamos el freno: dejamos la Red 1 entrenando **150** épocas sin parada temprana. Después de la época 44, justo donde el freno la había detenido, la validación empieza a empeorar mientras el entrenamiento sigue mejorando. Ahí empieza la memorización, y el freno la evitó a tiempo.

En la prueba 3 entrenamos a propósito una red gigante, de **187 mil** pesos y sin ninguna técnica contra la memorización, para tener un ejemplo real de memorización. Llegó a **99 %** de aciertos en entrenamiento pero solo **61 %** en validación. Nuestra red tiene **69,8 %** y **68,8 %**, casi iguales: no se parece en nada a una red que memoriza.

Iván continúa con las demás pruebas.

Iván Solano · diapositivas 13–16

Diapositiva 13: Pruebas 4 y 5: respuestas al azar y cantidad de datos

Gracias, Laura. La prueba 4 es la más contundente. Barajamos al azar las respuestas de los clientes, de modo que no había nada real que aprender.

Nuestra red se quedó en **0,5**, que es lo mismo que adivinar, y se detuvo sola. La red gigante, en cambio, llegó a **1,0** en entrenamiento: memorizó ruido. Como con las respuestas reales nuestra red llega a **0,754**, eso demuestra que aprende patrones reales.

En la prueba 5 entrenamos la misma red con cada vez más clientes. Con solo **695** clientes la red memoriza, con una diferencia de **0,177**. Con los **34.755** la diferencia baja a **0,012**: es el comportamiento típico de un modelo que generaliza.

Diapositiva 14: Resumen de la evidencia

En resumen, las cinco pruebas apuntan a lo mismo: las curvas van juntas, el freno actuó a tiempo, el modelo no se parece a una red que memoriza, no aprende ruido y la diferencia se cierra con más datos. Además, con los clientes del examen final el AUC solo bajó de **0,754** a **0,745**.

Sí existe una diferencia pequeña entre entrenamiento y prueba, pero es normal en cualquier modelo; memorizar se vería como la red gigante, con diferencias enormes. Por eso concluimos que el modelo aprendió.

Diapositiva 15: Cómo se mide el error (1): en la decisión

El error se puede medir de dos formas. La primera es contar: tomamos la decisión del modelo, APTO o NO APTO, y la comparamos con lo que realmente pasó. En el grupo de prueba, el error de clasificación es el número de fallos dividido entre el total: **2.422** entre **7.448**, es decir **32,5 %**.

De cada 100 clientes, se equivoca con 32. La precisión indica que, de cada 100 clientes que el modelo aprueba, 68 eran realmente buenos pagadores. La sensibilidad indica que, de cada 100 clientes buenos, el modelo encuentra a 66; y el F1 resume el equilibrio entre ambas medidas: **0,672**.

Diapositiva 16: Cómo se mide el error (2): en la probabilidad

La segunda forma mide qué tan buena es la probabilidad, antes de decidir. El log loss, o entropía cruzada, es el error que la red minimiza mientras entrena. Como ven en la gráfica, castiga poco una respuesta segura y correcta, y castiga muchísimo una respuesta muy segura pero equivocada.

Si el modelo no supiera nada y dijera siempre **50 %**, el log loss sería **0,693**; el nuestro es **0,596**. El Brier es el error cuadrático de la probabilidad: va de 0, que es perfecto, a **0,25**, que es decir siempre **50 %**; el nuestro es **0,205**.

Y el AUC, nuestra métrica principal, significa que si tomamos un cliente bueno y uno malo al azar, en 3 de cada 4 casos el modelo le da más probabilidad al bueno. Cristian les mostrará los resultados.

Cristian Martínez · diapositivas 17–20

Diapositiva 17: Resultados en el grupo de prueba

Gracias, Iván. Estos son los resultados del examen final con **7.448** clientes que el modelo nunca vio. El AUC es **0,745**, acertamos el **67,5 %** de los clientes y, frente a validación, el AUC solo cayó **1,2 %**, lo que indica que el modelo generaliza.

A la derecha ven cómo evolucionó el AUC desde la línea base hasta el modelo final. La mejora en prueba es de **0,0024**: es modesta, y lo decimos con honestidad. Para nosotros el aporte principal es el método: sin fuga de datos, con pruebas para cada decisión y reproducible.

Diapositiva 18: Aciertos, errores y su origen

Aquí está la matriz de confusión. En verde, los aciertos: **2.550** clientes riesgosos bien rechazados y **2.476** buenos bien aprobados. En rojo, los errores: **1.174** clientes riesgosos que el modelo aprobaría, que es el error más costoso para un banco, y **1.248** buenos que rechazaría, que es negocio perdido.

¿Por qué no acierta siempre? En la gráfica de la derecha vemos las probabilidades que el modelo da a los clientes buenos y a los malos: se mezclan en el centro. Hay muchas personas con datos casi idénticos y unas pagan y otras no, por causas que no están en los datos, como un despido o una enfermedad; ningún modelo puede separar lo que los datos no distinguen.

Diapositiva 19: Umbral de decisión y variables importantes

Dos usos prácticos del modelo. A la izquierda, el umbral: si el banco es más exigente y sube el umbral de **50 %** a **70 %**, la mora entre los aprobados baja de **4 %** a **2,1 %**, pero aprueba a muchas menos personas. Es una decisión de negocio, no del modelo.

A la derecha, las variables con más peso: el score crediticio concentra el **68 %** de la importancia, porque la forma en que una persona ha pagado antes es la mejor pista de cómo pagará después. Le siguen la tasa de interés y el número de créditos activos. Ojo: esto muestra asociación, no causa.

Diapositiva 20: Limitaciones, conclusiones y cierre

Queremos ser transparentes con los límites. La mejora frente a la línea base es modesta y no hicimos una prueba estadística formal; usamos una sola división de los datos; solo probamos redes de este tipo; y el umbral no está ajustado a los costos reales del banco.

Aun así, concluimos cuatro cosas: el modelo aprendió y no memorizó; cada decisión se tomó con evidencia, entrenando **164** redes; no hubo fuga de datos, porque el examen final se usó una sola vez; y el resultado es explicable, porque se apoya sobre todo en el historial de pago. Los invitamos a escanear el código para probar el evaluador en nuestra página.

Todos: Muchas gracias por su atención. Quedamos atentos a sus preguntas y comentarios.